SmolVLM 无需训练压缩实验报告

Sean-xzx · 2026 年 11 月 1 日 · professor-report-v3

0 主要结果

比较视觉 Encoder Top-K 与 LLM FFN Skip，无训练。SmolVLM-256M-Instruct 在 TextVQA、ScienceQA-IMG 各固定 256 题上评估六配置，共 12 组 3072 条预测。两方法分别运行，不叠加。

配置	TextVQA 软分 %	Δ pp	ScienceQA 准确率 %	Δ pp
baseline	54.4922	+0.0000	64.0625	+0.0000
early	43.5547	-10.9375	55.0781	-8.9844
middle	42.1484	-12.3438	58.2031	-5.8594
late	47.9688	-6.5234	60.5469	-3.5156
multi	13.6328	-40.8594	32.8125	-31.2500
skip	32.9688	-21.5234	32.4219	-31.6406

所有变体质量下降。Late 在四种 Top-K 中损失最小；Multi 虽减少 59.588%的 Encoder 主要 FLOPs，质量损失最大。Skip 固定 16 输出 token 的速度比为 0.993×/1.002×，同长度收益不明确。

压缩收益限于部分计算路径：Top-K 缩短 Encoder 内部序列，零回填后 LLM 视觉位置保持；六配置权重存储相同，allocated 峰值也未明显下降。完整成本与延迟见 § 2.3、 § 5。

任务 A 四问 · 任务 B · 任务 C 三问 · 验证 · 明细附录

1 实验协议

1.1 输入与生成

两集均用 validation，分别从 5000/2097 题以 Random(20261029)无放回抽 256 并升序，保存 ID、图像 SHA 和 meta。所有配置同图片、prompt、input IDs 及生成设置。模型/数据 revision、软件与硬件明细在附录 D1。

原生 Idefics3Processor 处理 RGB 图像，最长边 2048、图块 512，每块 1024 位置，无额外 CLS。Text 输入图片/问题/短答案指令，不加 OCR 字段；Science 另含原始非空 hint 和原序选项，不输入 answer、lecture 或 solution。

统一 RTX5090 Laptop、BF16、batch1、eager、eval/inference_mode、seed0、确定性、TF32 关闭；greedy、beam1、max_new_tokens64 及 EOS/cache 固定。eager 显式返回 Attention 权重，基线也用 eager，Flash/SDPA 未测。

1.2 评分

Text 原样复用 MMF 的 EvalAIAnswerProcessor 与 TextVQAAccuracyEvaluator：十参考逐一留出，以另九条匹配数 m 计算 min(m/3,1)，对十次留一及 256 题分别平均。因此是软分。Science 采用官方选项索引准确率定义，生成文本由本地 label-blind extract_choice v2 保守解析；未运行完整官方管线。

解析失败/空输出记 0 并保留 256 分母；执行异常标未完成，正式 3072 条无执行异常。Text 闭式复核与 normalizer 同源边界、Science 解析失败及实际 G 见附录 D。当前 Science64.0625%不代表复现官方 73.6% recipe。

2 任务 A Encoder Top K

2.1 方法与配置

令 a=x+Attention(norm1(x))。在 Attention 残差后、当前 FFN 前，对[块,head,query,key]权重以 FP32 平均 head 及有效 query，为各 key 打分。每块取 K=max(1,ceil(rate×当前有效数))个最高分，平分按原位置，选集恢复原序；gather(a)进入当前 norm2/MLP 及其残差，后层继续短序列。支持 1 起层列表和逐阶段比例。

配置	Encoder 层与阶段保留率	每块实际 K 及最终率	Skip 层
baseline	无	1024；100%	无
early	3；50%	512；50%	无
middle	6；50%	512；50%	无
late	9；50%	512；50%	无
multi	3→6→9；各 50%	512→256→128；12.5%	无
skip	无	1024；100%	8/16/24

12 层 Encoder 的 L/4、L/2、3L/4 恰为 3/6/9。单点分别独立；Multi 在同次前向的当前序列重新打分。各图块独立，padding 不参与评分/回填，边界处理见附录 A。

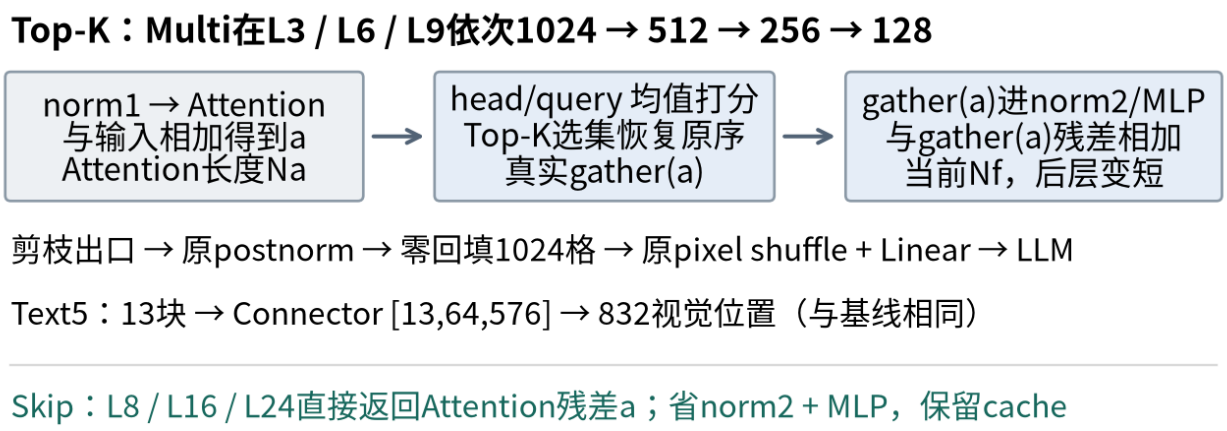


图 1 Top-K 缩短当前 FFN 及后层 Encoder，Skip 省独立 FFN 分支。来源：冻结代码与 context-v2 B4 Text row5，n=1 代表题；单位为 token/块和张量 shape，示意不作 Attention 归因。

2.2 必答 A1 参数与 Token

六配置 sum(p.numel())均为 256,484,928，原权重文件均 513,028,808 bytes；没有删权重或导出更小 checkpoint。Top-K 改变激活长度：单点出口 512、Multi128。剪枝当层 Attention 长度 Na 仍为旧值，FFN 长度 Nf 已缩短；后层 Attention 才变短。完整 12 层 Na/Nf 在附录 A。

2.3 必答 A2 Encoder 与全模型 FLOPs

乘加计 2。每视觉层主要 FLOPs 为：

$$8BNa\,dv^2 + 4BNa^2dv + 4BNf\,dv\,mv$$

三项依次为 QKV/O、QK/AV、fc1/fc2；B 为图块数，dv=768、mv=3072。按实际 Na/Nf 逐层求和，Early/Middle/Late/Multi 的 Encoder 本体分别减少 43.182%/29.545%/15.909%/59.588%。全模型还含 patch、Connector、LLM prefill/decode 及输出头，不能直接乘最终保留率。

附录 B 给六配置的 Encoder/全模型绝对成本、相对比例及完整公式，统一离线 G*=16、每集 256 题。该估算不是 512 题额外 fixed16 实测。打分、转换、排序与移动开销的计数/排除范围也在附录 B。

2.4 必答 A3 真实少算的证明

固定 Text row5，B=13、T=889。单点剪枝当层及下一层 fc1 pre-hook 均为[13,512,768]；原 addmm 的[13312,768]×[768,3072]变为[6656,768]×[768,3072]。Multi 三阶段如下，下一层继续相同短长度。

剪枝层→后层	两层 fc1 pre-hook	addmm 矩阵 A × B	CUDA μs 当前/后层
3→4	[13,512,768]	[6656,768] × [768,3072]	458.17 / 455.80
6→7	[13,256,768]	[3328,768] × [768,3072]	209.70 / 205.31
9→10	[13,128,768]	[1664,768] × [768,3072]	109.57 / 106.62

这是单次诊断 profiler，不能当稳定速度基准。附录 C 给五配置的 fc1/fc2 pre-hook、CPU/CUDA 时间及 Multi 后层 q_proj/QK/AV 矩阵，覆盖每次剪枝；完整 trace 由 E3 定位。

2.5 必答 A4 从视觉到 LLM

Text row5 输入[13,1024,768]，Encoder 出口为基线[13,1024,768]、单点[13,512,768]、Multi[13,128,768]。仅剪枝路径在原 postnorm 之后按原位置零回填，随后三者均走：

`Connector` 入口 `[13,1024,768]` → `pixel shuffle [13,64,12288]`

→ `Linear` 输出 `[13,64,576]` → `LLM` 视觉位置 `832`，总输入 `T=889`

postnorm 后回填使丢弃位置保持精确 0，原 Connector/LLM 位置契约不变。因此只减少 Encoder 内部计算，同 G 下 Connector 与 LLM 序列未缩短。832 是代表题数值，各题块数范围见附录 D。

3 任务 B Projector

方法	特征映射	Token 数量
Linear	逐位置线性投影	通常保持 N
MLP	逐位置多层 Linear 与非线性	通常保持 N
Q-Former	学习 query 跨注意力读取视觉特征	由 query 数决定
Perceiver Resampler	固定学习 latent 重采样视觉特征	由 latent 数决定；Flamingo 典型 64

本模型原 Connector 先 4×4 pixel shuffle 将 1024 位置合并为 64、通道 768 变 12288，再以单个无 bias Linear 投影至 576。SimpleMLP 类实际只有一个 Linear，数量变化来自 pixel shuffle。剪枝适配见 §2.5；这里仅作方法说明，未新增四组实验。BLIP-2、Flamingo §2.1/A.1.1 和实际连接代码供核查。

4 任务 C FFN Skip

4.1 层选择与残差

30 层 LLM 预先分散选 8/16/24 层同时 Skip，层列表可配置，未搜索最优层。目标层返回 a=x+Attention(inputnorm(x))，省整个 post_attention_layernorm 与 MLP；Attention、inputnorm、KV cache 及最终 norm 保留。实现见 skip_forward。

4.2 必答 C1 参数

实际总参数/权重文件与 §2.2 相同，仍注册在 state_dict。每个 gated FFN 含 3×576×1536=2,654,208 参数，三层停用 7,962,624；norm2 另 1,728。统计是停用计算的权重数，实际存储未减少。

4.3 必答 C2 FLOPs

T 含视觉与文本，G 为新生成 token 数。prefill 产生首 token，其后 G−1 次 cached decode；三层 FFN 主要矩阵节省为：

```
ΔFprefill = 15,925,248 T
ΔFdecode = 15,925,248 (G−1)
ΔFtotal = 15,925,248 (T+G−1)
```

系数为 3 层×6×576×1536。G=1 时 decode 为 0；Attention 仍 30 层、FFN27 层，norm2 不含于主要矩阵式。G*=16 时全模型仅省约 0.47%/0.49%（Text/Science）；完整分项见附录 B。

4.4 必答 C3 未执行的证明

旧 cost-perf-v1 Text row1848，B=13、T=888，记录 prefill 和一步独立 cache decode。每个目标层 L8/16/24 的计数如下。

配置	每阶段 inputnorm / Attention	每阶段 norm2 / MLP	两阶段各投影 marker 合计
baseline	1 / 1	1 / 1	gate/up/down 各 2 次
skip	1 / 1	0 / 0	全部缺席

非目标层正常。零调用结合投影区间缺席，证明未先算再丢弃。v3 独立 Text5 短 trace 另见 MLP 矩阵 180→162，减少 3 层×3 投影×2 阶段=18；不与主性能拼接毫秒。E4 原件注明样本/模块及范围。

5 实测效率与取舍

只用旧 cost-perf-v1 主基准：natural/first 每集 4 题，fixed16/stages 每集 1 题，各 2 预热 5 正式重复；总 780 正式/312 预热，锚点另计。同步计时从 GPU 已有输入至 native generate 返回，保留生产选择/回填/同步，不含加载、Processor、H2D、评分/I/O。

下表 fixed16 为同 G=16 的五次 median；速度比为同集基线 wall/变体 wall。自然 G 为另 4 题的均值，不能当 fixed16 的输出长度。逐题 Q1/Q3、自然/首 token 延迟及版本范围见附录 D 和原图源。

配置	Text fixed16 ms / 速度比	Science fixed16 ms / 速度比	自然 G 均值 T/S
baseline	414.22 / 1.000×	417.66 / 1.000×	6.5 / 3.5
early	338.77 / 1.223×	364.02 / 1.147×	6 / 4
middle	391.04 / 1.059×	374.21 / 1.116×	5.5 / 4
late	401.35 / 1.032×	412.21 / 1.013×	5.25 / 4
multi	323.14 / 1.282×	325.15 / 1.285×	5 / 3.5
skip	417.23 / 0.993×	416.89 / 1.002×	3.5 / 3

矩阵 FLOPs 减少不保证同比 wall 收益：排序、gather/零回填、CPU 同步与调度未全部计入主要 FLOPs。旧独立 Connector 回放剪枝约 4–5 ms、基线约 0.3–0.5 ms，但独立模块 median 不能相加减作端到端归因。Text Skip 自然 G 从 6.5 降到 3.5，少输出参与自然提速；fixed16 则未见明确收益。

allocated 峰值约 2902 MiB，剪枝略增、Skip 几乎相同；reserved 不能替代活跃显存。未锁频，旧锚点变化−2.46%/+3.83%；小样本/五次重复不构成总体置信区间。

6 正确性与执行证据

检查	比较对象	保存结果
单点 100% / Multi 全 100%，关闭额外路径	Text5/Science2×四模式：Encoder/ postnorm/Connector/prefill logits 及完整生成 IDs	32 张量最大误差 0，atol=rtol=0；IDs 相等，score/scatter 调用 0
空 Skip	两输入 prefill 及独立 cache 一步 decode 最后位置 logits、完整 IDs	最大误差 0，atol=rtol=0；IDs 相等

100%原生 bypass 不验证真实 50%选集/gather，后者由受控数值、pre-hook 与矩阵支撑（§2.4、附录 C）。Encoder 未单独比较 decode logits；非空 Skip 执行另见 §4.4。正常/受控异常清理通过，任意 OOM/kill 未验证。精选 E2 的 B2 索引是导航摘录，完整 proof/trace 在科学附件。

7 限制来源与复现

7.1 结论边界

结果支持固定两子集、单 GPU/BF16/batch1/eager 下的路径与取舍，未证明最优层或损失因果。所有负结果保留：Multi/Skip 质量损失大，权重存储未降，峰值未明显改善。Science Skip41 条解析失败全救回也仅 48.4375%，低于基线 64.0625%；不能用格式失败解释全部损失。

冷安装、跨机/其他 GPU、Flash/SDPA、新入口完整 256、v3 first/stages 及任意 OOM/kill 未验证。3072 质量、780 主性能、v3 迁移和新增 24 条不混用（附录 D3）。

7.2 来源与贡献

复用 Transformers4.57.6 的 Idefics3/Llama、Processor/generate 及 MMF 评分；Top-K/Skip 为必要实例级适配，Science 文本解析为本地实现。来源及改动、许可逐项保留。

AI 主要完成代码适配、实验编排、统计/自动核验及报告写作制图；Sean-xzx 提供任务与范围决策。核验包括原子结果重聚合、源 SHA、形状/调用记录和同源渲染。未声称 Sean-xzx 亲写、已审阅或独立掌握；教授指定现场环节须本人独立完成、不调用 AI/Agent。

7.3 复现入口

仓库提供代码/六配置/依赖锁、清单与精选证据；推理须另取完整科学包及固定模型缓存。按复现说明下载校 SHA、解包、准备数据，再运行 evaluate_release（新预测）、release_checks（正确性/性能/profiler）或 analyze_costs（只读 CPU 成本）；输出均为包外新目录。只读结构检查：python3 -B scripts/check_repository.py。原文覆盖见附录 E。

附录 A 完整逐层 Token

context-v2 Text row5，13 独立图块；每格 Na/Nf，单位 token/块。baseline 与 Skip 视觉路径相同。

层	baseline 及 skip	early	middle	late	multi
1	1024/1024	1024/1024	1024/1024	1024/1024	1024/1024
2	1024/1024	1024/1024	1024/1024	1024/1024	1024/1024
3	1024/1024	1024/512	1024/1024	1024/1024	1024/512
4	1024/1024	512/512	1024/1024	1024/1024	512/512
5	1024/1024	512/512	1024/1024	1024/1024	512/512
6	1024/1024	512/512	1024/512	1024/1024	512/256
7	1024/1024	512/512	512/512	1024/1024	256/256
8	1024/1024	512/512	512/512	1024/1024	256/256
9	1024/1024	512/512	512/512	1024/512	256/128
10	1024/1024	512/512	512/512	512/512	128/128
11	1024/1024	512/512	512/512	512/512	128/128
12	1024/1024	512/512	512/512	512/512	128/128

正式 24576 层记录 padding 均 0；受控有效数[16,5]按 ceil 得[8,3]→[4,2]→[2,1]。不同 K 用 Kmax 物理占位，padding 不参与 key/query 评分及原位置回填。Multi 复合原位置。受控记录中禁用 key 权重 109584 项最大 0、扰动 padding 不改有效输出；回填保留相等、丢弃精确 0。它们是有限样本/fixture 证明，不是任意输入保证。

附录 B FLOPs 公式与结果

B1 公式与计数范围

B 为图块数，N0=1024；视觉 dv=768、mv=3072、H=12。LLM d=576、m=1536、30 层、9Q/3KV、head64、d_kv=192、V=49280。FMA 计 2；Encoder 本体按 § 2.3 逐层 Na/Nf，其他项如下。

部分	主要 FLOPs
patch 卷积	$2BN0(3\times16^2)dv$
原 Connector	$2B\times64\times12288\times576$
LLM 每层 GQA 投影	$4qd(d+d_kv)$
LLM 每层 QK/AV	$4qsd$
LLM 每层 gated FFN	6qdm；基线 30 层、Skip27 层
输出头每次	$2\times1\times d\times V$，仅最后位置
全模型	patch + ΣEncoder + Connector + LLM prefill + Σdecode + G 个头

prefill 令 q=s=T；decode 第 j 步（j=1…G−1）令 q=1、s=T+j。n=G−1，则 $\Sigma s=nT+n(n+1)/2$；视觉/Connector 仅 prefill 一次。每题先按真实 B/T/G 计算再汇总，不能将平均 T 代入 T^2。Skip 三层节省见 § 4.3。

FP32 score 按 $BN^2(H+2)$基本算术、Attention cast 按每元素 BF16 读 2+FP32 写 4 bytes 单列，每阶段每块 3 次 stable argsort。bias、norm、激活、softmax/rope、比较排序、gather/scatter、CPU 循环/同步、KV 移动、查表及预处理/H2D/I/O 不并入主要矩阵总数；辅助字段在成本 CSV 与 components 保留。估算不是硬件指令实测。

B2 六配置绝对成本与相对变化

统一离线 G*=16，每集 n=256，逐题 GFLOPs 算术均值；T/S 为 Text/Science。Encoder 列不含 patch，全模型含上述主要项。实际 G 分项及 min/max 另在 costs.csv、ranges.csv，不与 fixed16 延迟混称。

配置	Encoder GF T/S	Encoder 比	全模型 GF T/S	全模型比 T/S
baseline	2903.33 / 2986.38	1.0000	3195.75 / 3309.64	1.0000 / 1.0000
early	1649.62 / 1696.81	0.5682	1942.04 / 2020.07	0.6077 / 0.6104
middle	2045.53 / 2104.04	0.7045	2337.95 / 2427.30	0.7316 / 0.7334
late	2441.44 / 2511.27	0.8409	2733.86 / 2834.53	0.8555 / 0.8564
multi	1173.29 / 1206.85	0.4041	1465.71 / 1530.11	0.4586 / 0.4623
skip	2903.33 / 2986.38	1.0000	3180.68 / 3293.32	0.9953 / 0.9951

附录 C 矩阵与 pre-hook 明细

C1 当前与后层 FFN

context-v2 B4 Text5，B=13、T=889、单次 prefill。fc1/fc2 实际 pre-hook、addmm 矩阵输入及同条 operator 的 CPU/CUDA μs 如下；诊断时间不相加、不作规范速度比。所有单点剪枝当层/后层和 Multi 三阶段均覆盖。

配置/层/模块	pre-hook	矩阵 A × B	CPU μs	CUDA μs
baseline L3 fc1	[13,1024,768]	[[13312,768],[768,3072]]	31.26	986.68
baseline L3 fc2	[13,1024,3072]	[[13312,3072],[3072,768]]	29.71	926.78
baseline L6 fc1	[13,1024,768]	[[13312,768],[768,3072]]	31.52	1047.13
baseline L6 fc2	[13,1024,3072]	[[13312,3072],[3072,768]]	29.94	982.17
baseline L9 fc1	[13,1024,768]	[[13312,768],[768,3072]]	30.63	1051.00
baseline L9 fc2	[13,1024,3072]	[[13312,3072],[3072,768]]	29.27	985.85
early L3 fc1	[13,512,768]	[[6656,768],[768,3072]]	49.42	450.59
early L3 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	33.90	414.59
early L4 fc1	[13,512,768]	[[6656,768],[768,3072]]	31.16	449.24
early L4 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	30.13	414.53
middle L6 fc1	[13,512,768]	[[6656,768],[768,3072]]	68.00	527.58
middle L6 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	36.73	494.30
middle L7 fc1	[13,512,768]	[[6656,768],[768,3072]]	32.56	526.72
middle L7 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	30.88	493.60

配置/层/模块	pre-hook	矩阵 A × B	CPU µs	CUDA µs
late L9 fc1	[13,512,768]	[[6656,768],[768,3072]]	105.30	446.30
late L9 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	45.39	407.96
late L10 fc1	[13,512,768]	[[6656,768],[768,3072]]	48.64	443.07
late L10 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	34.20	409.31
multi L3 fc1	[13,512,768]	[[6656,768],[768,3072]]	110.10	458.17
multi L3 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	54.32	421.50
multi L4 fc1	[13,512,768]	[[6656,768],[768,3072]]	50.16	455.80
multi L4 fc2	[13,512,3072]	[[6656,3072],[3072,768]]	36.48	422.24
multi L6 fc1	[13,256,768]	[[3328,768],[768,3072]]	46.99	209.70
multi L6 fc2	[13,256,3072]	[[3328,3072],[3072,768]]	35.62	188.99
multi L7 fc1	[13,256,768]	[[3328,768],[768,3072]]	32.46	205.31
multi L7 fc2	[13,256,3072]	[[3328,3072],[3072,768]]	55.58	189.41
multi L9 fc1	[13,128,768]	[[1664,768],[768,3072]]	46.56	109.57
multi L9 fc2	[13,128,3072]	[[1664,3072],[3072,768]]	35.34	98.24
multi L10 fc1	[13,128,768]	[[1664,768],[768,3072]]	43.11	106.62
multi L10 fc2	[13,128,3072]	[[1664,3072],[3072,768]]	33.25	96.51

C2 Multi 后层 Attention

L4/L7/L10 承接三次剪枝，q_proj pre-hook 分别[13,512/256/128,768]，B×H=156；下面为实际 q_proj/QK/AV 输入和 CPU/CUDA µs。完整 12 层矩阵与具名 score/select/scatter trace 见 E3。

层与算子	矩阵输入 A / B	CPU µs	CUDA µs
L4 q_proj	[[6656,768],[768,768]]	39.47	116.93
L4 QK	[[156,512,64],[156,64,512]]	27.13	246.43
L4 AV	[[156,512,512],[156,512,64]]	27.25	215.55
L7 q_proj	[[3328,768],[768,768]]	53.44	59.14
L7 QK	[[156,256,64],[156,64,256]]	27.11	50.62
L7 AV	[[156,256,256],[156,256,64]]	24.58	42.85

层与算子	矩阵输入 A / B	CPU µs	CUDA µs
L10 q_proj	[[1664,768],[768,768]]	42.19	34.27
L10 QK	[[156,128,64],[156,64,128]]	28.32	14.14
L10 AV	[[156,128,128],[156,128,64]]	24.86	12.70

附录 D 协议与统计明细

D1 固定版本与评分补充

对象	固定 revision
模型	7e3e67edbbed1bf9888184d9df282b700a323964
lmms-lab-encoder/textvqa	9c0699cd19768ac5ab97568f6b3cbac4c0062884
lmms-lab/ScienceQA-IMG	b9984af01798586705cee1fbdfa80a6dcbef04f1

两数据集均 default/validation。图片、抽样 ID/SHA 与 meta 见清单，协议见 eval_protocol_context_v2。Python3.10.12、torch2.7.1+cu128、Transformers4.57.6、RTX5090 Laptop24463 MiB、driver580.178.04；pixel_values 输入 FP32，原生模型按需转 dtype。

Text 十参考中标准化后有 c 次匹配时，闭式如下；1536 历史输出独立重聚合差异 0，但 normalizer 与 MMF/Pythia 同源。

```
s(c) = [(10−c) min(c/3,1) + c min(max(c−1,0)/3,1)] / 10
c=0,1,2,3,4,10 → s=0,0.3,0.6,0.9,1,1
```

MMF 固定源码、ScienceQA 准确率定义。Science hint 协议在控制诊断前冻结，旧无 hint58.984375% 不进入分差，官方 73.6%完整 recipe 未复现。

D2 长度与延迟统计

质量每组 n=256。G 为记录的新 token 数；下表为均值[min,max]，截断/解析失败均保留分母。截断列 T/S 分别为 Text/Science。

配置	Text G 均值与范围	Science G 均值与范围	截断 T/S	Sci 解析失败
baseline	5.273 [3,16]	4.500 [2,64]	0/1	1
early	5.309 [3,15]	3.914 [2,12]	0/0	1
middle	5.133 [2,18]	3.938 [2,26]	0/0	1
late	5.754 [2,64]	4.250 [2,33]	2/0	1
multi	6.316 [2,64]	4.082 [2,64]	5/2	28
skip	5.906 [3,64]	4.688 [2,64]	2/2	41

基线 256 题范围：Text B=9–17、T=622–1163、实际 G=3–16、总成本 2092.5–3991.7 GF；Science B=5–17、T=379–1394、G=2–64、1164.3–4081.6 GF。代表题 832 位置不代表所有图片。

下表为 cost-perf-v1：natural/first 取每集 4 题各 5 重复 median 的均值，fixed16 取每集 1 题 5 重复 median，单位 ms；每题另 2 预热。逐题 Q1/Q3 由 5 次实测排序的线性分位数得到，区间通常非对称，不是总体置信区间。数值/图源见 performance_samples.csv 及 fixed16 图/自然生成图。

数据/配置	natural ms	自然速度比	实际 G 均值	first ms	fixed16 ms / 速度比
T / baseline	297.235	1.000×	6.5	219.35	414.22 / 1.000×
T / early	193.208	1.538×	6	118.47	338.77 / 1.223×
T / middle	221.912	1.339×	5.5	156.62	391.04 / 1.059×
T / late	248.093	1.198×	5.25	182.99	401.35 / 1.032×
T / multi	167.404	1.776×	5	104.65	323.14 / 1.282×
T / skip	257.427	1.155×	3.5	221.71	417.23 / 0.993×
S / baseline	271.576	1.000×	3.5	236.52	417.66 / 1.000×
S / early	169.816	1.599×	4	129.78	364.02 / 1.147×
S / middle	213.897	1.270×	4	169.30	374.21 / 1.116×
S / late	249.613	1.088×	4	193.59	412.21 / 1.013×
S / multi	146.713	1.851×	3.5	110.84	325.15 / 1.285×
S / skip	253.235	1.072×	3	235.76	416.89 / 1.002×

780 正式/312 预热由 natural240、first240、fixed16 60、stages/decode240 组成；锚点另 20 正式。first 的 G=1，fixed16 通过 min=max_new_tokens16 控制，文本不进质量表。CUDA Event 为辅助 stream elapsed；单步 decode 用 fresh prefill cache 和固定基线首 token，wrapper 含位置/cache 构造。独立阶段 median 不相加减推因果。

D3 版本隔离与未验证范围

版本	用途与已验证范围
context-v2	原 3072 正式质量；本报告全部质量/pp 来源
cost-perf-v1	旧 780 正式/312 预热主性能；全部主毫秒与速度比来源
postday3-v3	同机热缓存迁移验证：120 正式/48 预热，锚点 20/8；不混入主性能；first/stages 未跑
20261031 薄入口	六配置×两集前 2 题共 24 条，新 raw/IDs/score 等与历史诊断相等；partial 单列，完整 256 未跑

同机共享解释器/HF 热缓存不能证明冷安装或跨机。完整科学包提供 512PNG、原子结果及 trace，轻量 Git 仅精选；来源/下载及 SHA 在发布说明。本报告只改呈现，不新增实验。旧 Release 报告及历史回执保留，不用于验证新版报告字节。

附录 E 原文检查定位

教授要求	本报告位置
模型/数据/评分/公平环境	§ 1；D1/D2
A1 参数/权重/逐层 Token	§ 2.2；附录 A
A2 Encoder/全模型 FLOPs 与额外开销	§ 2.3；B1/B2
A3 pre-hook/矩阵 shape/time 与 Multi 各阶段	§ 2.4；C1/C2
A4 Projector 入出/LLM 视觉位置	§ 2.5；图 1
B 四类方法及指定模型连接器	§ 3
C1 参数；C2 prefill/decode 成本；C3 执行证明	§ 4.2； § 4.3/B1； § 4.4
六配置 12 组、正确性、延迟/G/样本量	§ 0/ § 2.1； § 6； § 5/D2/D3
代码/复现/来源/AI/限制	§ 7；仓库 67 项映射

教授原文 · 67 项代码与证据映射 · E1–E8 证据索引 · 数据/评估/检查/性能运行命令