SmolVLM 无需训练压缩

视觉 Token 剪枝与 FFN Skip 的实验比较

Sean-xzx（GitHub 账号） · 2026 年 10 月 31 日

科学版本 postday3-v3 / context-v2 · AI 辅助提交候选版

1 研究问题与主要发现

本研究在 SmolVLM-256M-Instruct 原始权重上，比较视觉 Encoder Token Top-K 与 LLM FFN Skip 两种无需训练的方法。六配置分别使用两个数据集的同一组 256 题，共 12 组 3072 条正式预测。压缩的价值分别由质量、计算量、实测速度和存储回答。

四种 Encoder 剪枝确实缩短当前 FFN 与后续 Encoder 的序列，并减少主要矩阵量；所有质量指标均下降。Late 在四种 Encoder 配置中质量损失最小，Multi 的质量损失最大。Encoder 末尾回填规则网格适配原 Connector，LLM 视觉位置数保持不变。Skip 省略三层 FFN，但统一生成 16 token 时的旧主基准几乎没有收益。

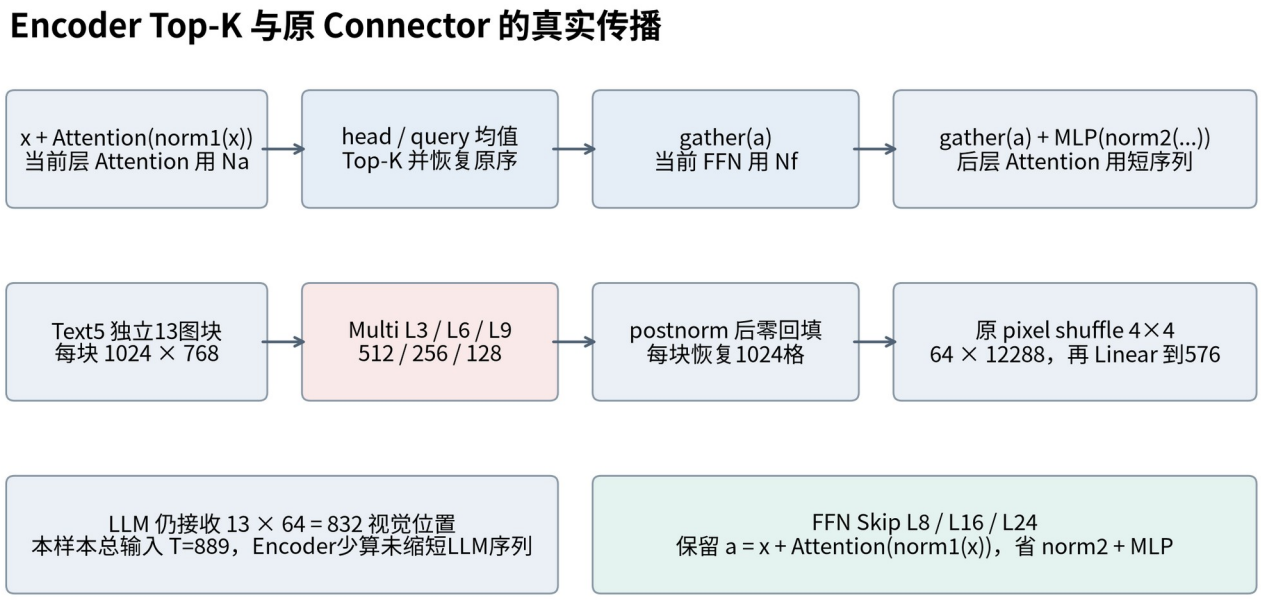


图 1 真实计算路径。TextVQA row5 有 13 个独立图块，T=889。示意依据 encoder_topk.py、ffn_skip.py 及 B4 实测形状，不是 Attention 归因图。

六配置总参数 256484928、原权重 513028808 bytes 均不变。没有证据显示显著 allocated 峰值节省。24 条新增预测只验证接收者入口，不替换正式 3072 质量或旧 780 性能。本文由 AI 依据保存记录完成写作与自动核验，未记录 Sean-xzx 已审阅或已独立完成技术交流。

2 实验协议与评分

固定模型为 HuggingFaceTB/SmolVLM-256M-Instruct，revision 为 7e3e67edbbed1bf9888184d9df282b700a323964。TextVQA 使用 lmms-lab-encoder/textvqa@9c0699cd19768ac5ab97568f6b3cbac4c0062884；ScienceQA-IMG 使用 lmms-lab/ScienceQA-IMG@b9984af01798586705cee1fbdfa80a6dcbef04f1。

两集均为 default/validation。各自独立用 Random(20261029)从总体 5000/2097 条中无放回取 256 并升序，保存 stable_id、row_index、图像 SHA 和清单 meta。各配置输入 prompt、input IDs 及图片一致。图像以 RGB 无损 PNG 随包提供；Idefics3Processor 执行原生 resize、rescale、normalize 和图像 splitting，最长边 2048，块 512。正式图片每块 1024 视觉位置，无额外 CLS。

Text 输入图片、问题和短答案指令，不加入 OCR 字段。Science 输入图片、非空原始 hint、问题、原序选项和选项字母指令。answer 仅在生成后评分，lecture/solution 均不进入输入或评分。hint 为合法题目背景，协议在控制诊断前冻结；旧无 hint 的 58.984375%不进入本报告分差。

本机正式环境为 Python3.10.12、torch2.7.1+cu128、Transformers4.57.6、RTX5090 Laptop 24463MiB、driver580.178.04。BF16、eager、batch1、eval/inference_mode、seed0、确定性、TF32 关闭。pixel_values 实际输入 FP32，由原生模型内部按需转 dtype。greedy、beam1、max_new_tokens64、原 EOS/cache，六配置一致。

两个评分对象

Text 使用原样 MMF EvalAIAnswerProcessor 及 TextVQAAccuracyEvaluator。每题十参考答案，留一后对另外九条的匹配数 m 计算 min(m/3,1)，再对十次留一平均，最后平均 256 题。若标准化后十条中有 c 次匹配，其闭式为：

```
s(c) = ((10-c) min(c/3,1) + c min(max(c-1,0)/3,1)) / 10
```

`c=0,1,2,3,4,10` 对应 `0,0.3,0.6,0.9,1,1`

因此 Text 结果是软分，不能解释为整数答对率。历史 1536 条 Text 输出的闭式聚合差异为 0；normalizer 与 MMF/Pythia 同源，不能称完全异源评分验证。

Science 指标采用官方选项索引准确率定义，实际生成文本由本地 extract_choice v2 保守、标签无关地解析。指标定义与文本解析是两个层次，未原样运行官方完整评测管线。空输出/解析失败保留原文、记 0 且保留 256 分母；推理异常保留错误并标未完成。旧正式 3072 条没有执行异常。证据 E1/E5，完整协议见 configs/eval_protocol_context_v2.json。

3 Encoder Top K 实现

记 a=x+Attention(norm1(x))。选择发生在 Attention 残差之后、当前 FFN 之前。原生 eager 权重为[图块,head,query,key]，先用 FP32 对 head 求均值，再在有效 query 上平均，得到每个 key 的 incoming attention 分数。无效 key 置为负无穷。没有把 key 维误当 query 维，也没有只修改 mask 来冒充真实少算。

每块 K=max(1,ceil(rate×当前有效 token 数))。按分数稳定降序取选集，平分时按原网格位置，随后恢复原始相对顺序。gather 后的 a 进入当前 norm2 和 MLP，输出为 gather(a)+MLP(norm2(gather(a)))。当前层 Attention 仍使用剪前 Na，当前 FFN 已使用剪后 Nf，下一层 Attention 才变短。

六配置

配置	Encoder 层	每阶段率	实际 K	最终率	Skip 层
baseline	无	无	1024	100%	无
early	3	0.5	512	50%	无
middle	6	0.5	512	50%	无
late	9	0.5	512	50%	无
multi	3/6/9	0.5/0.5/0.5	512/256/128	12.5%	无
skip	无	无	1024	100%	8/16/24

视觉 Encoder 共有 12 层，层号从 1 开始，L/4、L/2、3L/4 在本模型直接对应 3、6、9。Early、Middle、Late 独立 50%；Multi 在同一次前向依次用各层当前序列重新打分，1024→512→256→128，最终 12.5%。两类方法不叠加，Encoder 实验保持 LLM 结构不变，Skip 保持视觉分支不变。没有训练、比例/层扫描或最优组合搜索。

图块与 padding

每个图像块作为独立 batch 项，块内 Attention 独立执行。Text5 的 13 块不能合成长度 13312 的一条 Attention 序列。不同有效 K 用 Kmax 物理占位，padding 不参与 key、query 评分和回填。正式 24576 层记录 padding 均 0；人工有效数[16,5]的 ceil 测试依次得到[8,3]、[4,2]、[2,1]，只证明边界处理，不表示正式图像存在该 padding。

保留 token 的原位置在 Multi 中逐层复合，供 Encoder 之后的规则网格适配使用。保留特征已经经前层 Attention 混合信息，删除某位置不等于把其全部信息从模型中抹除。真实 50%路径、受控 mask/残差、独立选集重建和恢复证据见 E2/E3。

4 逐层 Token 与真实少算边界

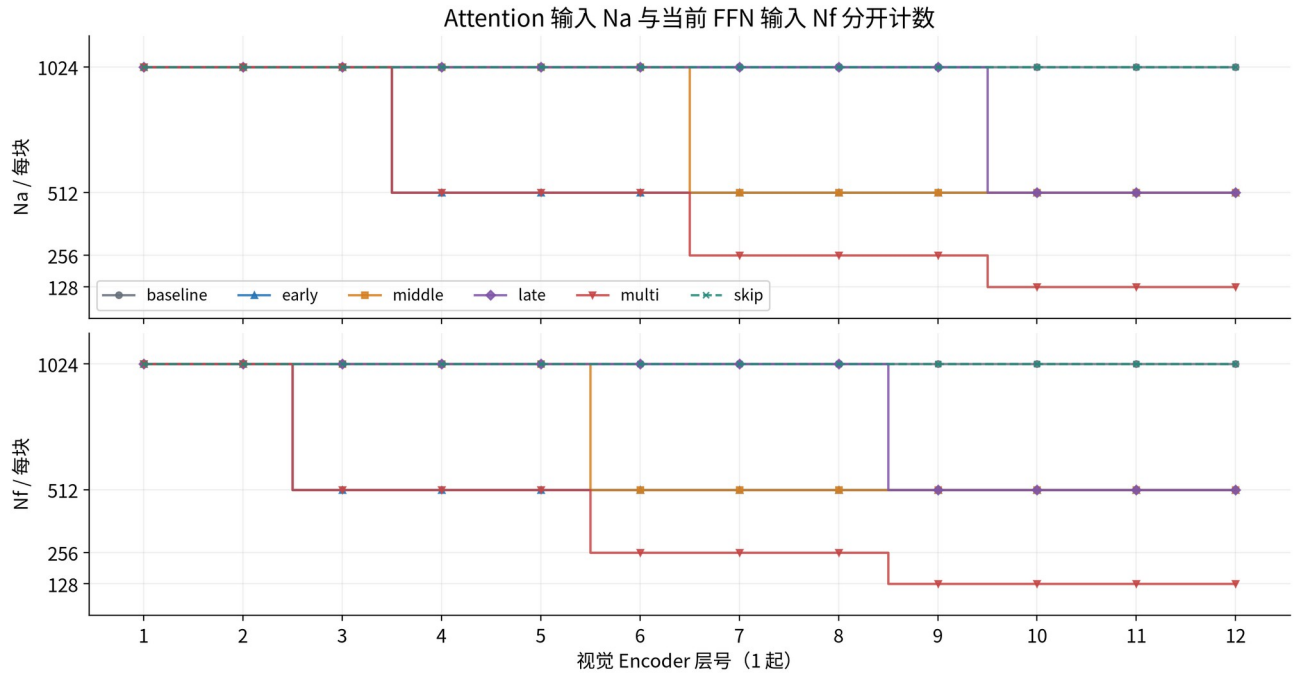


图 2 每块 Attention 输入 Na 和 FFN 输入 Nf。来自 Text5 B4/B6 实测，baseline 与 Skip 视觉路径相同；层号 1 起。

层	baseline	early	middle	late	multi
1	1024/1024	1024/1024	1024/1024	1024/1024	1024/1024
2	1024/1024	1024/1024	1024/1024	1024/1024	1024/1024
3	1024/1024	1024/512	1024/1024	1024/1024	1024/512
4	1024/1024	512/512	1024/1024	1024/1024	512/512
5	1024/1024	512/512	1024/1024	1024/1024	512/512
6	1024/1024	512/512	1024/512	1024/1024	512/256
7	1024/1024	512/512	512/512	1024/1024	256/256
8	1024/1024	512/512	512/512	1024/1024	256/256
9	1024/1024	512/512	512/512	1024/512	256/128
10	1024/1024	512/512	512/512	512/512	128/128
11	1024/1024	512/512	512/512	512/512	128/128
12	1024/1024	512/512	512/512	512/512	128/128

表内每格为 Na/Nf，单位 token/块。单点剪枝当层的 Na 仍为 1024，Nf 已为 512；Multi 第 6 层是 512/256，第 9 层是 256/128。完整两集逐层记录见 E3。Encoder 出口的稀疏长度分别为 1024/512/128，后续回填只发生在 Encoder 之后，不将丢弃 token 送回后层 Encoder。

5 Projector 与 FFN Skip

四类连接方式

模块	特征映射	对 token 数量 N 的典型作用
Linear	逐位置线性映射特征宽度	普通 pointwise 形式保持 N
MLP	多层 Linear 与非线性	普通 pointwise 形式通常保持 N
Q-Former	学习 query 通过视觉交互汇聚特征	输出由设计的 query 数决定
Perceiver Resampler	固定学习 latent 作为 query，跨注意力重采样视觉特征	输出等于 latent 数，与输入网格长度解耦

Perceiver Resampler 具体对应 Flamingo §3.1.1：学习 latent query 从可变长视觉特征中读入信息，典型输出 64 个视觉 token；其 key/value 还拼接视觉特征与 latent 特征。这比泛称 Perceiver IO 输出 query 更贴合视觉 Resampler。本研究只作概念说明，没有实现或训练额外连接器。Flamingo 原论文；Q-Former 见 BLIP-2。

本模型的真实 Connector

SimpleMLP 类实际只有一个无 bias Linear。1024→64 的数量变化来自前面的 4×4 pixel shuffle 空间合并，通道 768→12288，再 Linear 到 576；不能由类名认定这里有多层 MLP。剪枝分支先对保留特征执行原 post_layernorm，再按原位置 scatter 到零网格；零填在 postnorm 之后，避免其 bias 把占位零变为非零。

Text5 基线和剪枝分支最终均以[13,1024,768]规则网格进入 Connector，pixel shuffle 得到[13,64,12288]，Linear 输出[13,64,576]。LLM 视觉位置仍 13×64=832，总 prompt T=889。因此本适配只减少 Encoder 内部计算，未缩短原 Connector 或 LLM 的视觉序列。形状见 E3/E4 及冻结 HF 源码。

Skip 的残差与参数

在 30 层 LLM 的 8、16、24 层，同时省略 post_attention_layernorm（norm2）和 MLP，直接返回 a=x+Attention(inputnorm(x))。inputnorm、Attention、cache 保持。不是把 MLP 设 Identity 后再叠加 norm2(a)，也不是先计算再乘零。三层为预先分散覆盖，未验证最优。

每层无 bias gated FFN 有 3×576×1536=2654208 参数，三层共 7962624。另省三份 norm2 计算，权重 1728 参数；两部分均仍在 state_dict 中。总参数用 sum(p.numel())统计，六配置均 256484928；原权重 stat 为 513028808 bytes，未生成更小 checkpoint。停用计算、删除参数和文件压缩是不同量。调用计数及投影缺席见 E4。

6 正式质量结果

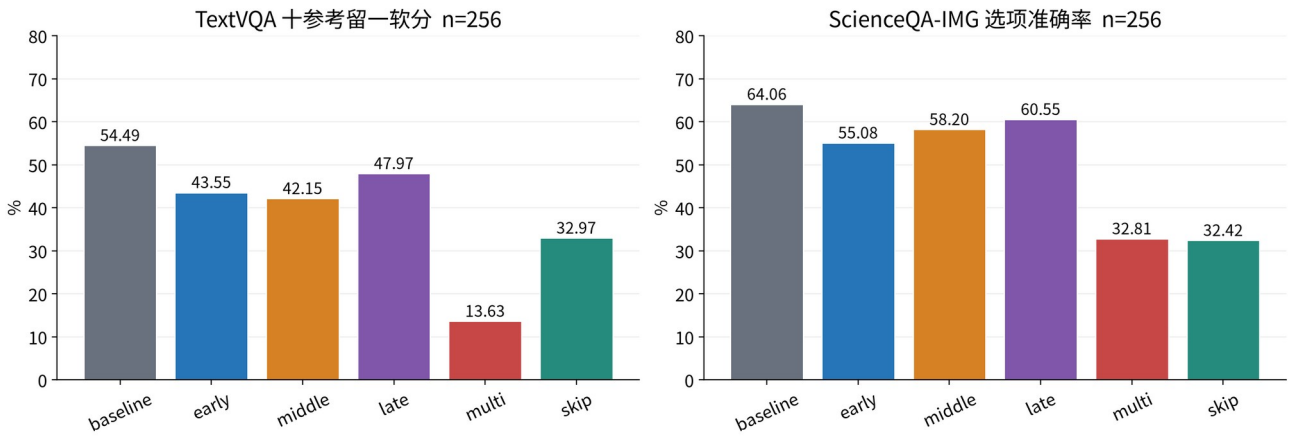


图 3 context-v2 正式质量，六配置各两集 256 题。纵轴从 0 起；Text 为软分，Science 为准确率。全部值从 3072 原子记录重新汇总。

配置	Text %	Δpp	Science %	Δpp	Sci 解析失败	截断 T/S
baseline	54.4922	+0.0000	64.0625	+0.0000	1	0/1
early	43.5547	-10.9375	55.0781	-8.9844	1	0/0
middle	42.1484	-12.3438	58.2031	-5.8594	1	0/0
late	47.9688	-6.5234	60.5469	-3.5156	1	2/0
multi	13.6328	-40.8594	32.8125	-31.2500	28	5/2
skip	32.9688	-21.5234	32.4219	-31.6406	41	2/2

12 组均完整，无异常、缺失或重复。所有分差都相对同版 context-v2 baseline。Late 的质量损失在四种 Encoder 中最小，不能据此称其效率或其他分布最优。Multi 和 Skip 的负结果保留，不为提高分数改解析器、删样本或重新选层。

Skip Science 有 41 条解析失败，即使这些全部救回，上界也只有 48.4375%，仍低于 baseline64.0625%；因此格式失败不能解释全部损失。这个上界不排除未标记的其他解析问题。Science baseline64.0625%不等于官方模型卡 73.6%的完整 recipe 复现；当前固定子集、提示和历史软件条件不同，不能直接把差距归因单一因素。证据 E1/E5。

7 Encoder 与全模型计算量

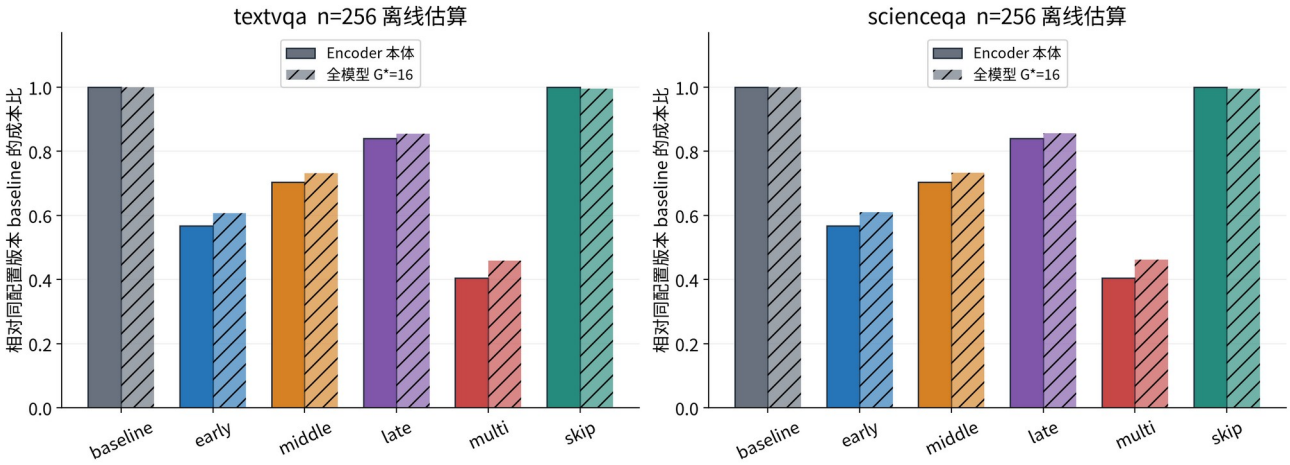


图 4 主要矩阵/卷积 FLOPs 相对同版 baseline 的比例。每集 256 题离线均值，乘加计 2；Encoder 本体不含 patch，G*=16 为统一工作量估算。

配置	Enc Text GF	Enc Sci GF	Enc 比	全 Text GF	全 Sci GF	全比 T/S
baseline	2903.33	2986.38	1.0000	3195.75	3309.64	1.0000/1.0000
early	1649.62	1696.81	0.5682	1942.04	2020.07	0.6077/0.6104
middle	2045.53	2104.04	0.7045	2337.95	2427.30	0.7316/0.7334
late	2441.44	2511.27	0.8409	2733.86	2834.53	0.8555/0.8564
multi	1173.29	1206.85	0.4041	1465.71	1530.11	0.4586/0.4623
skip	2903.33	2986.38	1.0000	3180.68	3293.32	0.9953/0.9951

GF 单位为单题均值十亿 FLOPs。Early、Middle、Late 的 Encoder 本体分别减少 43.182%、29.545%、15.909%；Multi 减少 59.588%。不能把最终保留 50%或 12.5%直接乘全 Encoder 或全模型。Skip 保持视觉计算，G*=16 全模型只省约 0.47%/0.49%，视觉分支在这批输入占主要计算量。

G*=16 是使用真实 T、图块数和模型维度的离线统一长度估算，没有为全部 512 题另跑固定 16 性能或质量。实际 G 成本与此分开保存，各 3072 行。辅助打分、排序、gather/scatter、同步和移动不被称为免费。证据 E6，完整均值/范围及每题表均保留。

8 计算公式与实际生成长度

记图块 B、初始 N0=1024、视觉 dv=768、mv=3072；LLM d=576、m=1536、30 层、9Q/3KV、head64，d_kv=192、词表 V=49280。Na/Nf 按第 4 节逐层使用。主要矩阵/卷积计数如下，乘加 2：

```
patch = 2 B N0 (3 × 16²) dv
vision_layer = 8 B Na dv² + 4 B Na² dv + 4 B Nf dv mv
Connector = 2 B × 64 × 12288 × 576
LLM_layer = 4 q d(d+d_kv) + 4 q s d + 6 q d m
head_each_call = 2 × 1 × d × V
prefill: q=s=T ; decode j=1..G-1: q=1, s=T+j
Skip 减少 = 3 × 6 × 576 × 1536 × (T+G-1)
```

首输出 token 归 prefill，后 G−1 步为 decode，G=1 时没有 decode；视觉和 Connector 只在 prefill 执行一次，输出头每次只处理最后位置。GQA 的 K/V 投影宽 192，Attention 按 query 总宽 576 计。总量逐项相加，Skip 的 FFN 层数为 27，Attention 仍 30。

实际 G 的全 256 题分项均值

任务	配置	视觉含 patch	Connector	prefill	decode	head	合计 GF
textvqa	baseline	2919.83	12.37	258.48	1.18	0.30	3192.16
textvqa	early	1666.12	12.37	258.48	1.19	0.30	1938.46
textvqa	middle	2062.02	12.37	258.48	1.14	0.29	2334.32
textvqa	late	2457.93	12.37	258.48	1.32	0.33	2730.43
textvqa	multi	1189.79	12.37	258.48	1.47	0.36	1462.48
textvqa	skip	2919.83	12.37	243.65	1.28	0.34	3177.47
scienceqa	baseline	3003.35	12.73	288.42	0.98	0.26	3305.73
scienceqa	early	1713.77	12.73	288.42	0.82	0.22	2015.96
scienceqa	middle	2121.01	12.73	288.42	0.83	0.22	2423.20
scienceqa	late	2528.24	12.73	288.42	0.91	0.24	2830.54
scienceqa	multi	1223.82	12.73	288.42	0.88	0.23	1526.08
scienceqa	skip	3003.35	12.73	272.34	0.98	0.27	3289.65

FP32 score 的基本算术按 $B \times N^2 \times (H+2)$单列，cast 按 BF16 读 2+FP32 写 4 bytes/元素；每 stage 每块 3 次稳定 argsort，另列 gather/scatter 与逐块 CPU 同步。bias、激活、RMS/softmax 部分基本运算在成本 CSV 单列。rope、查表、比较排序、KV 移动、预处理/H2D/I/O 等未并入主要矩阵总数。它是约定估算，不是逐硬件指令总数或硬件测得 FLOPs。

9 自然生成性能主基准

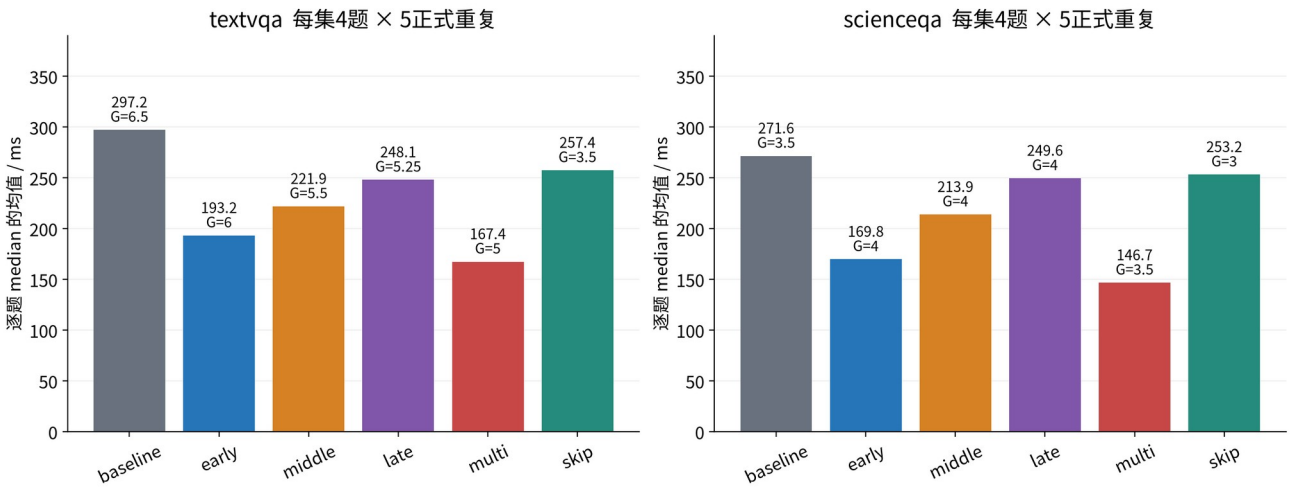


图 5 cost-perf-v1 自然生成。每集按长度选 4 题，每题 2 预热 5 正式；纵轴为逐题 median 的算术均值。图内 G 为对应 4 题平均实际生成长度。

任务	配置	wall ms	加速比	平均 G	峰值 MiB
textvqa	baseline	297.235	1.000	6.5	2901.84
textvqa	early	193.208	1.538	6	2901.99
textvqa	middle	221.912	1.339	5.5	2901.99
textvqa	late	248.093	1.198	5.25	2901.99
textvqa	multi	167.404	1.776	5	2901.99
textvqa	skip	257.427	1.155	3.5	2901.84
scienceqa	baseline	271.576	1.000	3.5	2902.27
scienceqa	early	169.816	1.599	4	2902.42
scienceqa	middle	213.897	1.270	4	2902.42
scienceqa	late	249.613	1.088	4	2902.42
scienceqa	multi	146.713	1.851	3.5	2902.42
scienceqa	skip	253.235	1.072	3	2902.27

计时为 GPU 上已有输入到 native generate 返回并同步，主机 perf_counter wall 为主。不含模型加载、图像解码、Processor、H2D、评分、I/O 和外部调试 hook；生产 score/sort/gather/scatter/同步保留。CUDA Event 是辅助 stream elapsed，不是纯 kernel 时间求和。自然 G 不同，Text Skip 从 6.5 降到 3.5，不能把自然速度改善全归因三层 FFN 少算。约 2902MiB 绝对 allocated 峰值几乎不变，剪枝略增，没有显示显著省显存。

10 固定长度与阶段测量

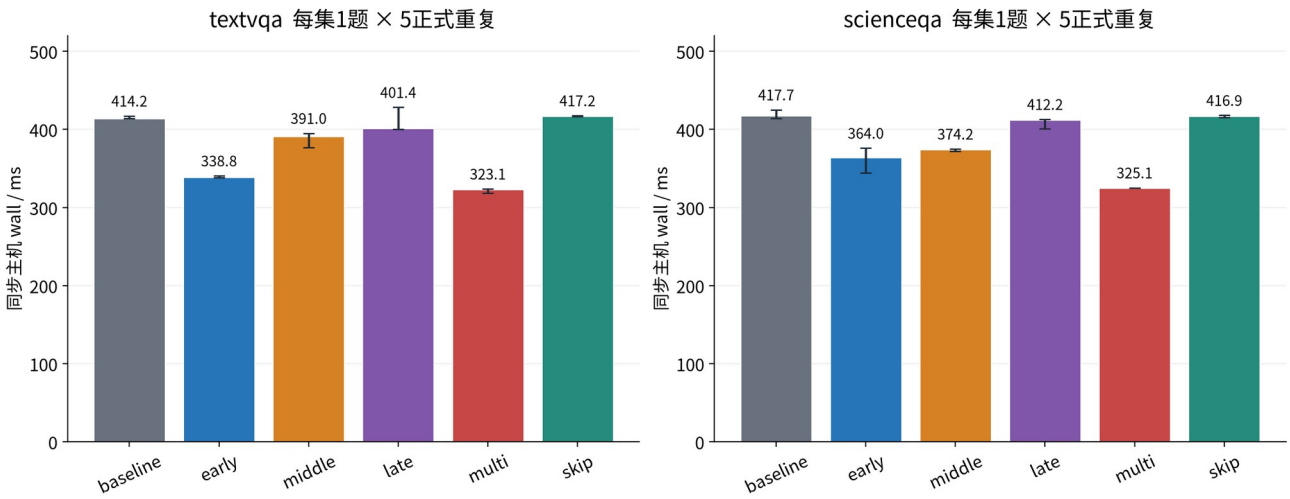


图 6 cost-perf-v1 固定 G=16，每集 1 诊断题、2 预热 5 正式。柱为 median，误差线为 IQR，不是总体置信区间。

任务	配置	首 token ms	固定 16 ms	固定 16 加速比
textvqa	baseline	219.35	414.22	1.000
textvqa	early	118.47	338.77	1.223
textvqa	middle	156.62	391.04	1.059
textvqa	late	182.99	401.35	1.032
textvqa	multi	104.65	323.14	1.282
textvqa	skip	221.71	417.23	0.993
scienceqa	baseline	236.52	417.66	1.000
scienceqa	early	129.78	364.02	1.147
scienceqa	middle	169.30	374.21	1.116
scienceqa	late	193.59	412.21	1.013
scienceqa	multi	110.84	325.15	1.285
scienceqa	skip	235.76	416.89	1.002

首 token 为每集 4 题的逐题 median 均值，fixed16 每集仅 1 题。Skip 固定 16 为 0.993×/1.002×，未显示明确同长度收益；Early 为 1.223×/1.147×，Multi 为 1.282×/1.285×，均伴质量损失。fixed16 用 min=max_new_tokens16 改变停止行为，文本不进正式质量表。

旧主基准共 780 正式/312 预热：natural240、first240、fixed16 60、stages/decode240；首尾锚点另 20 正式。锚点变化 Text−2.46%、Science+3.83%，未过 10%线。没有锁频，小 n 和硬件波动仍限制外推。独立模块 median 不能相加为端到端，也不能用总 wall 减 vision 推出 LLM 耗时。单步 decode 每次用 fresh prefill cache 和固定 baseline 首 token，wrapper 含位置/cache 张量构造，不是纯 kernel。

11 正确性证据分别证明什么

检查对象	保存证据与比较范围	结果与边界
单点 100%及 Multi 全 100%	两输入×四模式，Encoder/postnorm/Connector/prefill logits；完整生成 IDs	32 张量比较最大误差 0，atol/rtol=0；未单独比较 Encoder decode logits
空 Skip	两输入 prefill 与独立 cache 一步 decode 最后位置 logits，完整 IDs	最大误差 0，atol/rtol=0；cache 独立
关闭额外路径	100%原生旁路	score/scatter 调用 0，只证明无压缩一致性
真实 50%/ Multi	四配置各 4 真实样本、受控 mask/残差与选集重建	当前 FFN 及后层真实短；不由 100%旁路替代
padding 与原序	有效[16,5]受控输入；24 真实 stage 独立重建 1D 评分选集	禁用 key 权重 109584 项最大 0；扰动 padding 不改有效输出
grid 适配	postnorm 后保留位置比较及丢弃位置	保留相等、丢弃精确 0；原 Connector 复用
清理	全 named_modules forward/hook 集合、参数身份/指针/version	正常退出及五配置受控异常恢复；任意 OOM/kill 未验证

以上为旧 context-v2 及 v3 保存的实测证明，本轮只读提取，没有重新跑全部 proof。100%走原生旁路，所以它不检验 50%分数排序或 gather 的实现；真实剪枝由独立受控数值、pre-hook 与矩阵证据支撑。有限固定样本通过不等于任意输入形式的数学保证。

Skip 真实未执行

旧 skip_trace 在基线与 Skip 同输入 prefill 和一步 decode 分别计数：目标 L8/16/24 的 norm2 和 MLP 为 0，Attention/inputnorm 各 1 次每阶段；gate/up/down 目标 CPU 区间缺席，其他层正常。v3 短 trace 另见 MLP 投影矩阵 180→162，三层×三投影×两阶段共减少 18。零调用与矩阵缺席结合说明没有先算再丢弃。不能把 CPU marker 时间与嵌套 GPU 事件重复相加。直接索引 E2/E3/E4/E7。

存储与显存的证据边界

所有权重仍注册，因此参数停用不是 checkpoint 缩小。allocated 峰值几乎相同，reserved 是分配器历史，不能代替活跃显存或权重大小。早期仍为 1024 的密集 Attention 可能决定峰值，此解释与形状相容，但没有独立内存分配时间线因果定位，不能写成已证明原因。

12 当前 FFN 与后层矩阵证据

固定 Text5、T=889、B=13，单次诊断 prefill。下表为 fc1 的 pre-hook 及 aten::addmm 输入，证明当层 FFN 及下一层已收到短张量；完整 fc1/fc2 见 figures/matrix_evidence.csv 及 E3 JSON。13 块可在 Linear 中展平 BN 行，Attention 仍为 $B \times N^2$。

配置	层	pre-hook 形状	二维矩阵输入	CPU us	CUDA us
baseline	3	[13, 1024, 768]	[[13312, 768], [768, 3072]]	31.26	986.68
baseline	6	[13, 1024, 768]	[[13312, 768], [768, 3072]]	31.52	1047.13
baseline	9	[13, 1024, 768]	[[13312, 768], [768, 3072]]	30.63	1051.00
early	3	[13, 512, 768]	[[6656, 768], [768, 3072]]	49.42	450.59
early	4	[13, 512, 768]	[[6656, 768], [768, 3072]]	31.16	449.24
middle	6	[13, 512, 768]	[[6656, 768], [768, 3072]]	68.00	527.58
middle	7	[13, 512, 768]	[[6656, 768], [768, 3072]]	32.56	526.72
late	9	[13, 512, 768]	[[6656, 768], [768, 3072]]	105.30	446.30
late	10	[13, 512, 768]	[[6656, 768], [768, 3072]]	48.64	443.07
multi	3	[13, 512, 768]	[[6656, 768], [768, 3072]]	110.10	458.17
multi	4	[13, 512, 768]	[[6656, 768], [768, 3072]]	50.16	455.80
multi	6	[13, 256, 768]	[[3328, 768], [768, 3072]]	46.99	209.70
multi	7	[13, 256, 768]	[[3328, 768], [768, 3072]]	32.46	205.31
multi	9	[13, 128, 768]	[[1664, 768], [768, 3072]]	46.56	109.57
multi	10	[13, 128, 768]	[[1664, 768], [768, 3072]]	43.11	106.62

CPU us 为该算子主机总区间，CUDA us 为关联设备时间。单次 profiler 用于检查执行路径和矩阵 shape/time，不能替代规范延迟。Multi 在 L3、L6、L9 分别用 512、256、128，L4、L7、L10 也持续缩短；剪枝当层 Attention 仍是旧 Na。fc2 相应输入为[13,K,3072]，矩阵为[13K,3072]×[3072,768]。

每配置完整 12 层 QKV/O、QK/AV、fc1/fc2，以及 score/select/scatter 的具名区间均在 B4 各配置 JSON/trace；v3 独立短 profiler 再次覆盖 Multi 三个 stage 及 Skip 目标。旧证据引用与本轮实际新 24 条分开，不把文件存在称为本轮重新执行通过。

13 代表题与子集范围

TextVQA row5 的 baseline 原始输出为“22.”，Multi 为“2.”，得分 1→0。该案例按照预定类别的最小原索引选择，不是事后挑选最好看的样例。原图如下；没有生成虚假的 Attention 热图。



图 7 TextVQA 固定 row5 原图，来自随包 RGB PNG。baseline 与 Multi 使用同图同 prompt；该题 13 独立图块，LLM 视觉位置均 832。原图/问题/参考答案/原始输出以原子 JSON 为准，版权归原图权利人。

Science row165 的 baseline“Answer: C”、Late“Answer: A”，得分 1→0；row42 baseline“Answer: C”、Multi“Answer: B”，得分 1→0。row60 Skip 输出含互相矛盾的表达，保守解析拒绝。完整 raw、参考和类别规则见 E5 failure_cases.json。

这些记录说明固定输入下计算改变伴随质量和格式损害；未做 Attention 归因实验，不能声称已定位被删文字 patch，或证明 Multi 因某个具体对象被删除而答错。

基线 256 题实际长度与成本范围

任务	图块 B 范围	输入 T 范围	实际 G 范围	总 GF 范围
textvqa	9–17	622–1163	3–16	2092.5–3991.7
scienceqa	5–17	379–1394	2–64	1164.3–4081.6

每题输入/输出长度、全部配置实际 G 与固定 G16 成本均有原表；figures/ranges.csv 保留每组 min/max，quality.csv 保留 G 均值/min/max 和截断数。性能题按长度选取，不是对全部 512 题延迟总体的随机推断；5 次重复也不是 5 个独立任务。

14 接收者新评估入口验证

旧 evaluate_context.py 完成过正式评估，但有历史环境/证明门禁；replay_release.py 能迁移路径，却强制预测与历史逐字一致且没有完整汇总。因此本轮增加 evaluate_release.py 薄入口，显式读取 artifact-root，复用原加载、问题构建、补丁、generate、评分、原子保存和 summarize，不复制模型或另造评分框架。

新运行保留模型 revision、科学源/配置/manifest/协议 SHA 和必要依赖检查，当前 Python 二进制/GPU 环境另行绑定。历史环境 ID 只是引用，不伪造为本轮环境。逐题保存新生成 raw/new IDs、prompt/input IDs、分数、解析、T/G、错误和时间。历史相等只输出诊断，生成差异不直接等于实现失败。

配置	Text 索引	Science 索引	预测数	partial	本机历史诊断
baseline	5,19	2,9	4	是	全部相同
early	5,19	2,9	4	是	全部相同
middle	5,19	2,9	4	是	全部相同
late	5,19	2,9	4	是	全部相同
multi	5,19	2,9	4	是	全部相同
skip	5,19	2,9	4	是	全部相同

2026 年 10 月 31 日真实串行执行六进程，每配置加载模型一次、处理两集各前 2 题，共 24 条。六命令 exit0，ID 正确、24 条完整、无异常或解析失败；prompt/input IDs/shapes/raw/new IDs/score/parse/T/G 均与本机历史相同。partial_mean_score 不写成全 256 分数，正式 mean_score 为空，原 3072 主表保持不变。精确 argv/cwd/开始结束/退出码/日志/SHA 见 verification/commands.json 与 NEW24_ACCEPTANCE.json。

运行职责

接收者先准备独立 Python 依赖和固定模型/Processor/tokenizer 缓存，再获取完整包、核 SHA、解包。数据就绪检查核对随包 512PNG，不是数据下载器。新预测评估用本轮入口；严格精确重放、正确性、性能/profiler 和 CPU 成本沿用完整包入口。所有输出位于包外新空目录。

可直接复制的完整命令见 docs/REPRODUCTION.zh.md。轻量 Git 不含全部父证据和图片，必须与完整科学包组合；命令不需要作者机器的固定路径。新入口 limit256、冷安装、跨机器尚未实测；本轮不为文档重跑主实验。

15 独立解包验证与版本隔离

postday3-v3 是旧科学资产的迁移功能验证。保存回执记录独立解包后 27 条命令 exit0，512PNG SHA 通过，100%/空 Skip 比较最大误差 0，六配置各两集首题 12 条严格重放对齐，CPU 两套 3072 行成本重算字节相同。最终包与已测 RC 的执行/输入文件 SHA 一致，文稿修改后没有重复 GPU。

v3 性能每集 1 诊断题，六配置 natural/fixed16 各 5 正式、2 预热，共 120 正式 48 预热；首尾锚点另 20/8。下面独立列出 v3 固定 16，不与旧 780 毫秒或 baseline 拼接。

任务	配置	fixed16 median ms	IQR ms	同版加速比
textvqa	baseline	417.908	15.144	1.000
textvqa	early	340.159	22.275	1.229
textvqa	middle	372.487	5.300	1.122
textvqa	late	409.724	37.793	1.020
textvqa	multi	328.193	10.412	1.273
textvqa	skip	410.736	2.944	1.017
scienceqa	baseline	428.611	10.214	1.000
scienceqa	early	344.996	11.775	1.242
scienceqa	middle	371.340	1.314	1.154
scienceqa	late	412.326	8.225	1.039
scienceqa	multi	329.655	12.849	1.300
scienceqa	skip	417.230	1.875	1.027

v3 锚点 Text−1.5501%、Science−1.1601%，未触发 10%线。小样本验证表明迁移路径在同机共享解释器/HF 热缓存工作，不代表跨机冷启动或整个数据分布。v3 first/stages、严格 replay limit256 未实跑。旧 780、v3 120、新 24 条是三套不同范围；新 24 条的调度时间也不是规范性能测量。包外 FINAL_RECEIPT 及 E7 保存完整边界。

原 v3 包 455733348 bytes，SHA256 d95a7774653f0b35f5e7cb37619807c27b0d295e0494 d29b90b4be22bcec0d4d。它不担保本轮新增文稿/入口；新增文件使用本轮清单和提交版本。公开发布的实际状态单独见 docs/PUBLICATION.zh.md，不用本地文件冒充线上附件。

16 讨论与适用边界

质量与计算的取舍

Late 保留更多层的完整视觉交互，当前质量较好而成本节省较小；Early 成本节省更多，质量下降更明显。Multi 叠加三次选择，质量损失极大。这些是本固定协议下的观察，不能解释为已证最优位置或已确定质量损失的唯一机制。没有训练、消融扫描、语义归因或补偿模块实验。

FLOPs 与时间为什么不成比例

主要矩阵量没有包含稳定排序、gather、零回填、CPU 同步和框架调度等全部开销。本实现显式取 eager Attention 权重，baseline 也使用 eager；Flash/SDPA 后端未测，不能外推部署加速。旧独立 Connector 回放中剪枝约 4–5ms、baseline 约 0.3–0.5ms，与适配开销有实际落点，但模块独立 median 不能相减或相加为端到端分解。

自然生成还受实际 G 影响。Skip 减少三个 FFN 的矩阵量相对全模型很小，固定 16 几乎不变；自然少输出时 wall 缩短并不能证明同工作量提速。部分独立模块 median 顺序不符合包含关系，可能受时钟/调度/执行顺序影响，当前未通过配对实验定位具体原因。

外推与未验证范围

只有一个 GPU、BF16、batch1、eager 及两个固定 validation 子集。质量与离线成本每集 256，规范性能自然/first 每集 4 题、fixed16/stages 每集 1 题、各 5 重复，未给总体置信区间。没有明显存储或 allocated 峰值下降证据。官方 73.6%历史 recipe 未完整复现，Text 标准化同源，Science 文本解析是本地适配，均保留在结论边界中。

接收者新入口完整 256、独立依赖安装、冷模型/数据下载、跨机运行未测试；v3 first/stages 未运行；未重建全部历史 proof。既有失败日志原样保存，不通过禁用 assert、修改 hash 或参考结果消除差异。本轮未发现需要重做主科学结论的确切新缺陷。

可支持的结论

该实现真实缩短 Encoder 内部计算张量，并在本机小基准测得部分速度改善，代价是质量下降；它不减少 LLM 视觉序列、权重存储或显著 allocated 峰值。三层 FFN Skip 在当前选择上质量代价大，同长度收益不明确。这一负结果本身构成比较结论，不需要通过追分或隐藏配置改成正面结果。

17 来源与实际贡献

模型/Processor/generate 与 Idefics3/Llama 直接复用 HF Transformers4.57.6；EncoderTopKPatch 和 SkipPatch 是基于固定源码的实例级必要适配。Text 评分文件原样复用 MMF，Science 准确率定义参考官方实现，文本解析为本地标签无关适配。成本/计时复用原项目 helper，未复制完整训练或评测框架。

本轮 AI 完成接收者薄入口、24 条真实推理编排与验收、数据只读提取、图表/图注、报告正文与排版、证据索引、汇报与练习准备。旧实验记录已披露 AI 主要代码适配、实验编排、统计与自动核验。Sean-xzx 提供任务、约束、公开选择和范围决策；没有证据的人工原稿、逐题人工核实、审阅、练习或独立掌握不作声明。

已执行检查是自动检查：原子记录汇总、历史 SHA 绑定、新 24 条预测/摘要校对、真实渲染检查。报告/汇报材料是准备成果，不证明未来现场指定环节已由用户独立完成；该环节可查代码文档，应按教授要求不调用 AI/Agent。未进行的用户审阅与个人能力验收分别记录于交接。

固定来源导航

1. 模型固定 revision，Transformers4.57.6；源码 SHA/许可见完整包 evidence/day1_morning/sources 及 docs/SOURCES_AND_CHANGES.zh.md。

2. TextVQA 挑战评分说明；MMF 固定评分源码。聚合独立、normalizer 同源，详细 1536 条检查见 E5。

3. ScienceQA 官方准确率定义。本地 extract_choice 源码与边界检查见 E5。

4. 题目 Token 压缩参考，仅方法参考，未运行音频框架；LLaVA projector builder。

5. BLIP-2 Q-Former；Flamingo Perceiver Resampler §3.1.1。本轮补清固定学习 latent 语义，不引入新模型依赖或实验。

上游许可按文件保留，没有将混合工程统一声明 MIT/Apache。图表数值全部取自 figures/source_inputs.json 登记的真实记录；保存 CSV/JSON、绘图脚本、SVG/PNG 和 figure_manifest。原稿母版为本 Markdown，同源导出 Word 再生成 PDF，避免维护不同正文。

阅读和复现入口

接收者命令页、证据索引 E1 至 E8、教授逐项映射、公开状态。完整源/图表与离线技术交流材料由 README 统一导航。