# SmolVLM 无需训练压缩实验报告

Sean-xzx（GitHub 账号） · 2026 年 10 月 31 日

报告版 professor-report-v2 · 科学底稿 context-v2 / cost-perf-v1 / postday3-v3

## 0 概要与阅读路线

在 SmolVLM-256M-Instruct 原始权重上，比较四种视觉 Encoder Top-K 与三层 LLM FFN Skip。六配置在 TextVQA、ScienceQA-IMG 各固定 256 题上完成 12 组、3072 条正式预测。任务 A 保持 LLM 不变，任务 C 保持 Encoder 不变；任务 B 只解释连接方法，没有新增连接器实验。

主要发现是计算量减少伴随质量损失。Late 的两集分数为 47.9688%/60.5469%，相对基线下降 6.5234/3.5156 pp，已是四种 Encoder 剪枝中损失最小的一组。Multi 的 Encoder 主要 FLOPs 减少 59.588%，但质量降至 13.6328%/32.8125%。Skip 固定 16 输出 token 的速度比仅 0.993×/1.002×，没有明确同长度收益。

Encoder 内部缩短不等于端到端视觉序列缩短：剪枝特征经 postnorm 后零回填再走原 Connector，LLM 视觉位置保持。六配置总参数 256,484,928、原权重 513,028,808 bytes 均不变，约 2902 MiB 的 allocated 峰值也未明显下降。

阅读顺序为实验协议→任务 A 四问→任务 B→任务 C 三问→统一结果→执行证明。附录 A 给完整逐层 Token，B 给公式及成本分项，C 给矩阵形状与耗时，D 给统计/版本，E 给原文覆盖索引。性能结论限于同机小样本，新增 24 条薄入口验证不进入正式质量表。

任务 A · 任务 B · 任务 C · 结果 · 证明 · 附录

## 1 实验设计与评分

### 1.1 固定输入与公平比较

模型为 HuggingFaceTB/SmolVLM-256M-Instruct。版本如下；均为 default 配置，数据使用 validation。

| 对象 | 固定 revision |
| --- | --- |
| 模型 | 7e3e67edbbed1bf9888184d9df282b700a323964 |
| lmms-lab-encoder/textvqa | 9c0699cd19768ac5ab97568f6b3cbac4c0062884 |
| lmms-lab/ScienceQA-IMG | b9984af01798586705cee1fbdfa80a6dcbef04f1 |

每集独立用 Random(20261029)从 5000/2097 题无放回抽 256 并升序，保存 stable_id、row_index、图像 SHA 与 meta。六配置使用相同图片、prompt 和 input IDs。随科学包提供 512 张 RGB 无损 PNG；Idefics3Processor 原生 resize/rescale/normalize 与图像 splitting，最长边 2048、图块 512，每块 1024 视觉位置，无额外 CLS。

Text 输入图片、问题和短答案指令，不添加 OCR 字段。Science 输入图片、非空原始 hint、问题、原序选项及字母答案指令；answer 仅在输出后评分，lecture/solution 不作输入。hint 协议在控制诊断前冻结，旧无 hint 基线 58.984375%不参与本报告分差。

正式环境为 Python3.10.12、torch2.7.1+cu128、Transformers4.57.6、RTX5090 Laptop 24463 MiB、driver580.178.04。统一 BF16、eager、batch1、eval/inference_mode、seed0、确定性、TF32 关闭；pixel_values 输入实际为 FP32，由原生模型按需转 dtype。greedy、beam1、max_new_tokens64 及原 EOS/cache 一致。eager 显式取得 Attention 权重，基线也用 eager；Flash/SDPA 未测。

### 1.2 两个指标及失败规则

Text 采用原样 MMF EvalAIAnswerProcessor 和 TextVQAAccuracyEvaluator：每题十参考，依次留出一个参考，用其余九个的匹配数 m 计算 min(m/3,1)，对十次留一再平均。十条中标准化后有 c 次匹配时：

```
s(c) = [(10−c) min(c/3,1) + c min(max(c−1,0)/3,1)] / 10
c = 0, 1, 2, 3, 4, 10  →  s = 0, 0.3, 0.6, 0.9, 1, 1
```

该指标是软分，不能当作整数答对率。1536 条 Text 历史输出独立闭式重聚合差异为 0；normalizer 仍与 MMF/Pythia 同源，未构成完整异源评分器验证。

Science 使用官方选项索引准确率定义，生成文本用本地 extract_choice v2 保守、label-blind 地解析。官方指标与本地文本解析分开说明：没有原样运行官方完整管线。空输出/解析失败记 0 并保留 256 分母；执行异常保留错误并标未完成。正式 3072 条无执行异常。Science 基线 64.0625%不等于完整复现模型卡 73.6%的历史 recipe。协议、清单及评分证据见 E1/E5。

# 2 任务 A Encoder Top K

## 2.1 算法与四配置

记 a=x+Attention(norm1(x))。在 Attention 残差后、当前 FFN 前，取原生权重[块,head,query,key]，以 FP32 先平均 head，再在有效 query 上平均，得到每个 key 的 incoming attention 分数；无效 key 置负无穷。

每块 K=max(1,ceil(rate×当前有效数))。稳定降序选最高 K，平分以原网格位置为序；选集再按原位置升序，真实 gather(a)进入 norm2 与 MLP。输出为 gather(a)+MLP(norm2(gather(a)))。当层 Attention 仍用旧长度 Na，当层 FFN 先用短长度 Nf，后层 Attention 才变短。支持升序 1 起层列表和逐阶段比例，拒绝越界/重复层；实现见 prune_layer。

| 配置 | Encoder 层号 | 阶段保留率 | 实际 K 及最终率 | Skip 层 |
|---|---|---|---|---|
| baseline | 无 | 无 | 1024；100% | 无 |
| early | 3 | 50% | 512；50% | 无 |
| middle | 6 | 50% | 512；50% | 无 |
| late | 9 | 50% | 512；50% | 无 |
| multi | 3→6→9 | 各 50% | 512→256→128；12.5% | 无 |
| skip | 无 | 无 | 1024；100% | 8/16/24 |

Encoder 共 12 层，L/4、L/2、3L/4 恰为 3/6/9。三个单点分别独立运行；Multi 同一次前向在每个阶段当前序列重新打分。没有训练、层/比例扫描或两方法叠加。

图块各自作为 batch 项，TextVQA row5 的 13 块不能当一条 13312 长序列。不同有效 K 以 Kmax 物理占位，padding 不参与评分/回填；正式 24576 层记录 padding 均 0。受控有效数[16,5]按 ceil 依次得[8,3]→[4,2]→[2,1]，只验证边界处理。Multi 逐层复合原位置，保留特征已混合前层信息，不能由位置删除推断信息完全消失。

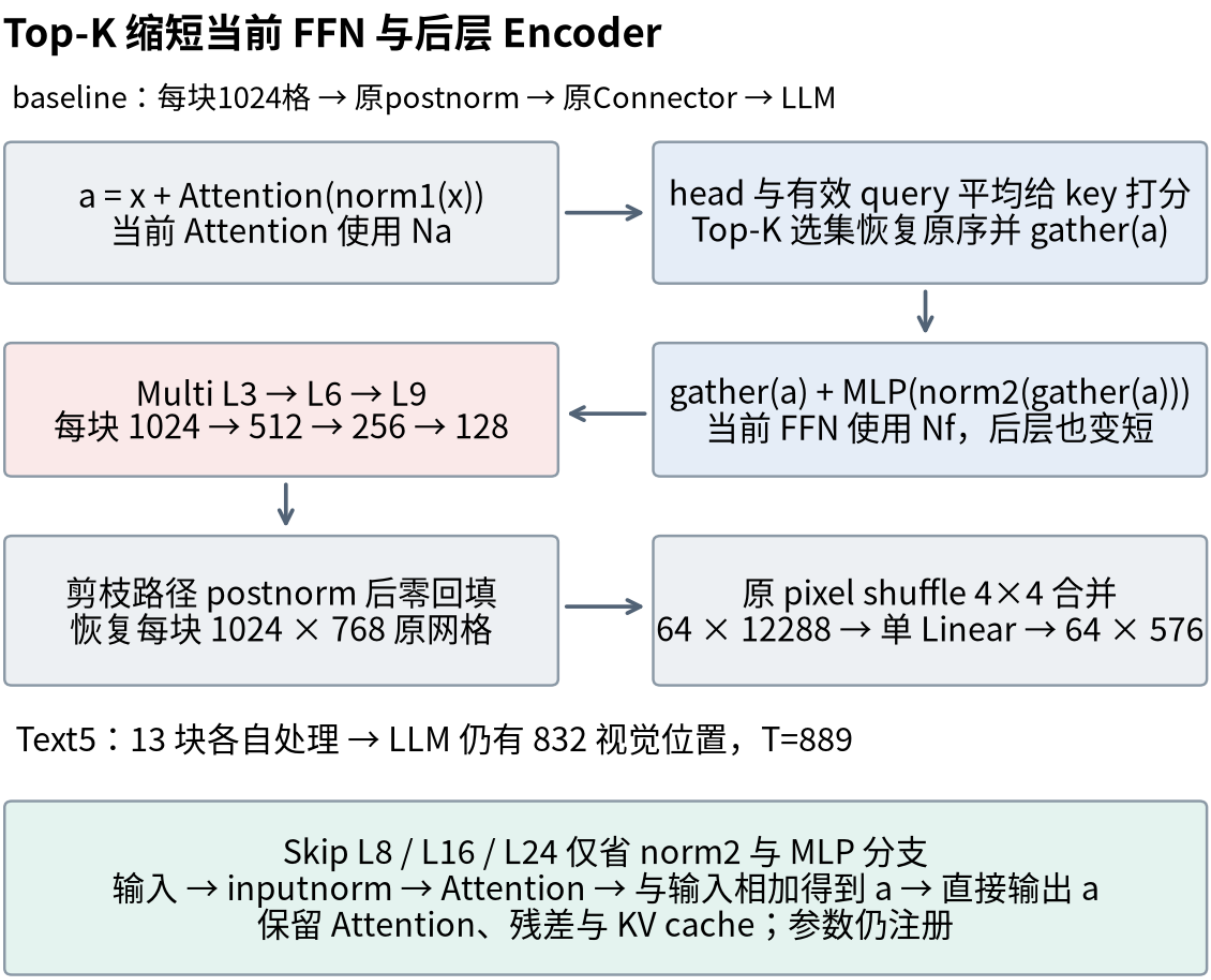



图 1 少算发生在 Encoder 内部及 Skip 分支，LLM 视觉位置不变。来源：encoder_topk.py、ffn_skip.py 与 context-v2 B4 Text row5 形状；n=1 代表题，单位为 token/块与特征维度，流程示意无统计误差或归因含义。

### 2.2 必答 A1 参数存储与逐层 Token

六配置实际注册参数 sum(p.numel())均 256,484,928，原模型权重文件 stat 均 513,028,808 bytes；未导出更小 checkpoint。Top-K 改变激活序列，不删参数。每块 Encoder 稀疏出口由 1024 变为单点 512 或 Multi128，分别减少 50%/87.5%，但前面已执行的层并未同比减少。图 2 区分 Na 与 Nf，完整 12 层数值见附录 A。

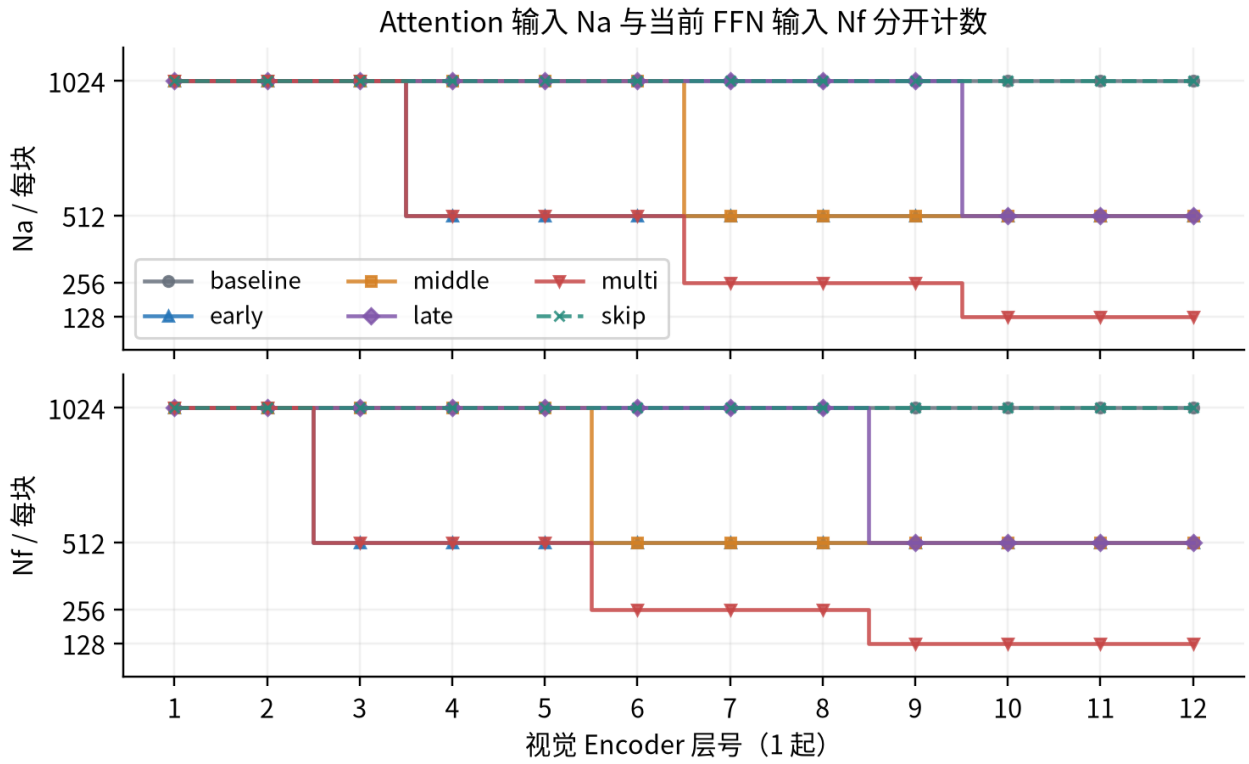



图 2 剪枝当层 FFN 先变短，Attention 到下一层才缩短。来源：context-v2 B4/B6 Text row5 直接记录；n=1 代表题、13 独立块，单位 token/块；baseline 与 Skip 重合，无跨题均值或误差带。

### 2.3 必答 A2 Encoder 与全模型 FLOPs

乘加计 2，仅汇总主要矩阵/卷积。单视觉层为 $8BNa\,dv^2+4BNa^2dv+4BNf\,dv\,mv$，分别包含 QKV/O、QK/AV 和两个 FFN 矩阵。按附录 A 逐层求和，不能用最终保留率乘整模型。dv=768、mv=3072。

统一离线 G*=16 时，Early/Middle/Late 的 Encoder 本体减少 43.182%/29.545%/15.909%，Multi 减少 59.588%；全模型两集成本比例分别为 0.6077/0.6104、0.7316/0.7334、0.8555/0.8564、0.4586/0.4623。具体 GFLOPs 见 § 5.2，完整 prefill/decode 推导、实际 G 分项及选择开销见附录 B。G*=16 是离线估算，不是 512 题额外 fixed16 实测。

FP32 打分算术按 $BN^2(H+2)$，转换按每 Attention 元素读 2 写 4 bytes；每阶段每块 3 次稳定 argsort。比较排序、gather/scatter、CPU 循环和同步、KV 移动等不纳入主要 FLOPs，仍保留在生产计时中。少矩阵量不保证等比例 wall 收益。

### 2.4 必答 A3 被丢弃 Token 未进入 FFN 和后层的证明

Text row5 固定 B=13、T=889 的 pre-hook 直接观测：Early L3/L4 的 fc1 输入均[13,512,768]，Middle L6/L7 与 Late L9/L10 亦为该形状。Multi L3/L4、L6/L7、L9/L10 依次为 K=512/256/128。fc1 实际 addmm 从[13312,768]×[768,3072]缩为[13K,768]×[768,3072]，fc2 同样缩短。对应 CPU/CUDA 微秒在附录 C 逐项列出；后层 Attention 的 q_proj 及 QK/AV 矩阵也在那里给出，覆盖每次剪枝后计算。

这些是实际输入与算子记录，100%旁路一致性不能替代。详细 E3 提供 JSON/trace；诊断 profiler 单次耗时用于路径核验，不作为规范速度统计。

### 2.5 必答 A4 从视觉输入到 LLM 的传递

稀疏 Encoder 出口经原 post_layernorm，再将保留特征按原位置 scatter 到零网格；零回填只在剪枝适配路径，且在 postnorm 之后，避免 norm bias 改变占位零。原 Connector 的 pixel shuffle 和 Linear 不变。Text row5 的实际路径如下。

| 位置 | baseline / skip | 单点 Top-K | Multi |
|---|---|---|---|
| Encoder 输入 | 13×1024×768 | 13×1024×768 | 13×1024×768 |
| Encoder 稀疏出口 | 13×1024×768 | 13×512×768 | 13×128×768 |
| 原 Connector 入口 | 13×1024×768 | 回填 13×1024×768 | 回填 13×1024×768 |
| pixel shuffle 后 | 13×64×12288 | 13×64×12288 | 13×64×12288 |
| Linear 输出 | 13×64×576 | 13×64×576 | 13×64×576 |
| LLM 视觉位置 / 总 T | 832 / 889 | 832 / 889 | 832 / 889 |

单位为张量 shape 或 token。剪枝没有减少本样本的 LLM 视觉位置、Connector 计算和同 G 下 LLM 长度；832 是该代表题数量，各题块数不同（附录 D）。保留位置回填精确相等、丢弃位置精确 0，见 § 6。

## 3 任务 B Projector

本节仅作文字说明，不增加四种连接器实验。特征宽度映射与 token 数量变化是不同设计维度。

| 方法 | 如何映射特征 | 对 token 数量的作用 |
|---|---|---|
| Linear | 逐位置乘权重矩阵 | pointwise 形式保持 N |
| MLP | 逐位置多层 Linear 与非线性 | pointwise 形式通常保持 N |
| Q-Former | 学习 query 通过跨注意力读取视觉特征 | 输出由设计的 query 数决定 |
| Perceiver Resampler | 固定学习 latent 作 query 重采样；Flamingo 将视觉与 latent 特征拼入 K/V | 输出为 latent 数，典型 64，与输入网格长度解耦 |

指定模型沿用 HF Idefics3 Connector：先 4×4 pixel shuffle 空间合并，使每块 1024 位置变为 64、通道 768 变为 12288，再以无 bias Linear 投影到 576。SimpleMLP 类名在此并不表示多层网络，实际只有一个 Linear。数量下降来自空间合并，特征宽度下降来自 Linear。

剪枝后如何接入见 § 2.5 的零网格适配；这保留了原位置/尺寸契约，也使 LLM 序列未继续缩短。代码见 connect 与 restore_grid，原生 HF 代码及许可见来源清单。概念来源为 BLIP-2 Q-Former、Flamingo § 2.1 及附录 A.1.1 与 LLaVA projector builder。

# 4 任务 C FFN Skip

## 4.1 三层选择与残差归一化

30 层 LLM 中预先分散选 8、16、24 层同时 Skip，未搜索最优层。SkipPatch 支持 1 起层列表并检查范围/重复。每个目标层保留 input_layernorm、Attention、KV cache 及残差，输出 a=x+Attention(inputnorm(x))，省去整个 post_attention_layernorm 与 MLP 分支；最终 norm 保留。不是将 MLP 改为 Identity，也没有先算再乘零。实现见 skip_forward。

## 4.2 必答 C1 存储参数与停用 FFN 参数

按 sum(p.numel())统计，六配置总参数与权重文件大小仍为 § 2.2 数值。每层 gated FFN 的 gate/up/down 三个无 bias 矩阵共有 3×576×1536=2,654,208 参数，三层共 7,962,624；另外省去三份 norm2 计算，对应 1,728 个权重。它们仍在 state_dict 中，因此停用计算不等于实际存储减少。

## 4.3 必答 C2 prefill 与 decode 成本

输入长度 T 包括视觉位置和文本。生成 G 个新 token 时，首输出归 prefill，其后 G−1 次 cached decode。三层 FFN 节省为：

```
ΔFprefill = 3 × 6 × 576 × 1536 × T
ΔFdecode = 3 × 6 × 576 × 1536 × (G−1)
ΔFtotal = 15,925,248 × (T+G−1)
```

G=1 时 decode 为 0；Attention 仍 30 层、FFN 变为 27 层。该主要矩阵公式不含 norm2 等辅助运算。视觉与 Connector 只在 prefill 执行一次。G*=16 离线统一成本下，Skip 全模型仅减少约 0.47%/0.49%；实际 G 的各分项和范围见附录 B/D，规范同长度实测见 § 5.3。

## 4.4 必答 C3 调用与 profiler 证明

旧 cost-perf-v1 固定 Text row1848、B=13、T=888，分别记录一次 prefill 及独立 cache 一步 decode。每个目标层、每个阶段的实测计数如下。

| 目标层 | 配置 | inputnorm / Attention | norm2 / MLP | 投影 marker 合计 |
|---|---|---|---|---|
| 8 | baseline | 1 / 1 | 1 / 1 | 各 2 次合计 |
| 8 | skip | 1 / 1 | 0 / 0 | 均缺席 |
| 16 | baseline | 1 / 1 | 1 / 1 | 各 2 次合计 |
| 16 | skip | 1 / 1 | 0 / 0 | 均缺席 |
| 24 | baseline | 1 / 1 | 1 / 1 | 各 2 次合计 |
| 24 | skip | 1 / 1 | 0 / 0 | 均缺席 |

表中 norm/MLP/Attention 为每阶段调用数，gate/up/down marker 为两阶段合计；原记录缺少的目标项按 0 计。非目标层正常，final norm 每阶段 1 次。v3 另一个 Text row5 短 trace 中，两阶段 MLP 投影矩阵数 180→162，恰减少 3 层×3 投影×2 阶段=18；不将其毫秒混入主性能。零调用结合投影区间缺席，支持目标 FFN 确实未计算，未声明所有生成步都有 trace。原件见 E4。

# 5 统一结果与取舍

## 5.1 全部配置质量下降

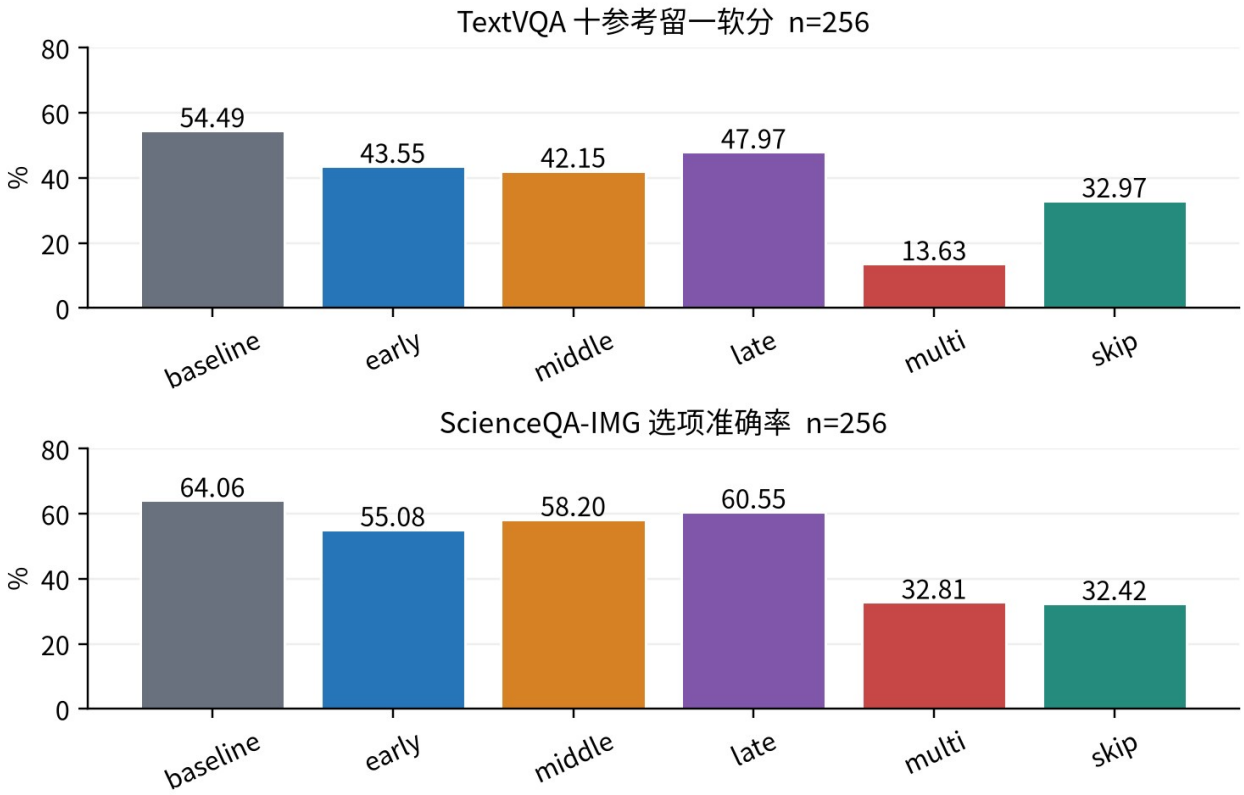



图 3 所有变体均低于同版基线。来源：context-v2 原 3072 条逐题 score；每组 n=256，算术均值×100，单位%，轴从 0 起；解析失败记 0 保留分母。Text 为十参考留一软分，Science 为选项准确率。

| 配置 | Text % | Δ pp | Science % | Δ pp | Sci 解析失败 |
|---|---|---|---|---|---|
| baseline | 54.4922 | +0.0000 | 64.0625 | +0.0000 | 1 |
| early | 43.5547 | -10.9375 | 55.0781 | -8.9844 | 1 |
| middle | 42.1484 | -12.3438 | 58.2031 | -5.8594 | 1 |
| late | 47.9688 | -6.5234 | 60.5469 | -3.5156 | 1 |
| multi | 13.6328 | -40.8594 | 32.8125 | -31.2500 | 28 |
| skip | 32.9688 | -21.5234 | 32.4219 | -31.6406 | 41 |

Late 在四种 Encoder 变体中质量损失最小，Multi/Skip 损失很大。Skip Science 的 41 条解析失败即使全救回，上界 48.4375%仍低于基线 64.0625%，格式失败不能解释全部损失；该上界不排除其他未标记解析问题。未通过改解析器或删题提高报告分数。

真实失败例为 Text row5：baseline 输出“22.”、Multi 输出“2.”，分数 1→0；相同输入的 LLM 视觉位置均 832。案例按预定类别最小原索引选择，完整 raw/参考见 E5。没有 Attention 归因实验，不能断言删掉某文字 patch 导致错误。

### 5.2 理论计算量和实际存储分开

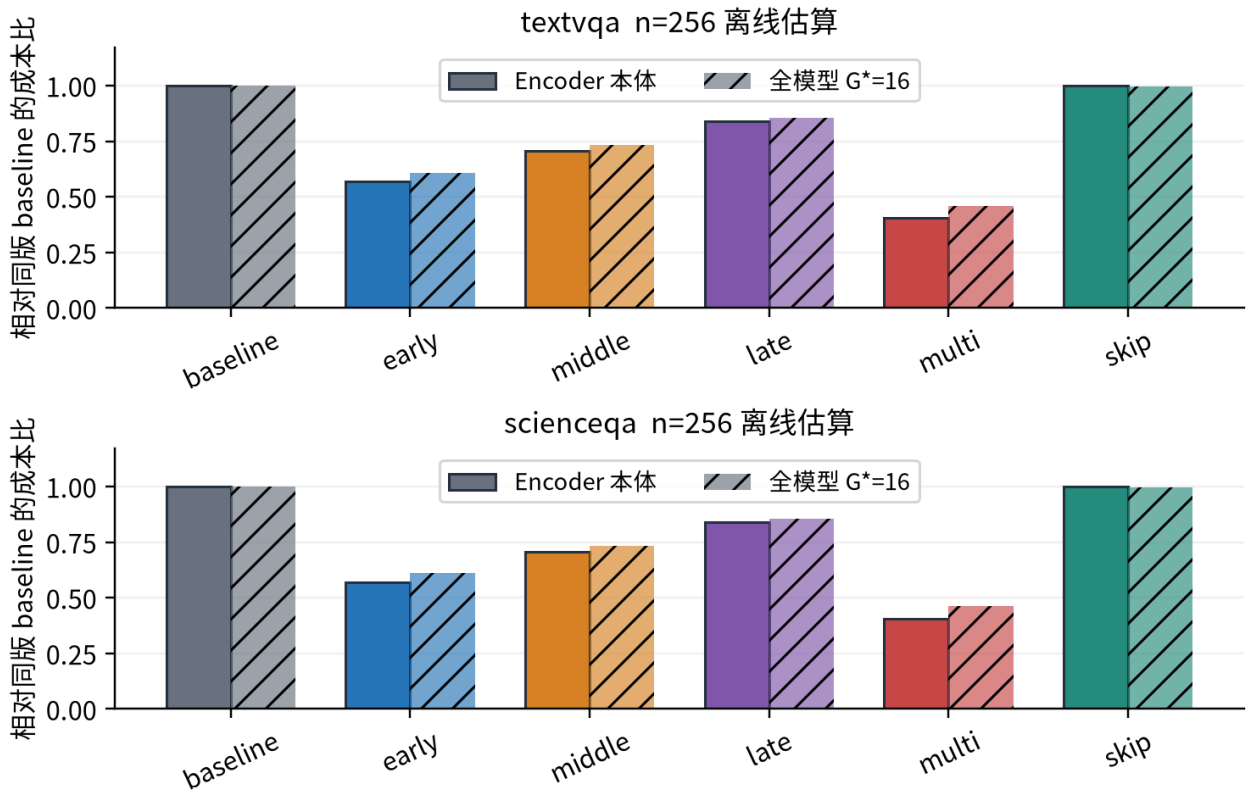



图 4 Encoder 节省不能直接当作全模型节省。来源：cost-perf-v1 costs_G16.csv，真实 T/B、离线 G*=16，每集 n=256；各组 GFLOPs 均值相对同集基线之比，单位为比例，乘加计 2；Encoder 本体不含 patch。

| 配置 | Encoder GF T/S | Encoder 比 | 全模型 GF T/S | 全模型比 T/S |
|---|---|---|---|---|
| baseline | 2903.33 / 2986.38 | 1.0000 | 3195.75 / 3309.64 | 1.0000 / 1.0000 |
| early | 1649.62 / 1696.81 | 0.5682 | 1942.04 / 2020.07 | 0.6077 / 0.6104 |
| middle | 2045.53 / 2104.04 | 0.7045 | 2337.95 / 2427.30 | 0.7316 / 0.7334 |
| late | 2441.44 / 2511.27 | 0.8409 | 2733.86 / 2834.53 | 0.8555 / 0.8564 |
| multi | 1173.29 / 1206.85 | 0.4041 | 1465.71 / 1530.11 | 0.4586 / 0.4623 |
| skip | 2903.33 / 2986.38 | 1.0000 | 3180.68 / 3293.32 | 0.9953 / 0.9951 |

T/S 分别为 TextVQA/ScienceQA-IMG，GF 为单题均值十亿 FLOPs。两集块数不同而 Encoder 相对比相同。参数/权重均未变（§2.2、§4.2），理论成本下降不是文件压缩或已证明的峰值内存下降。

### 5.3 固定长度与自然生成延迟

主性能只用 cost-perf-v1：natural/first 每集 4 道按长度选取的题，fixed16/stages 每集 1 道诊断题，每题 2 预热 5 正式重复。780 正式/312 预热分为 natural240、first240、fixed16 60、stages/decode240；首尾锚点另计 20 正式。同步包围 GPU 已有输入到 native generate 返回，perf_counter 主机 wall 为主；不含加载、解码图片、Processor、H2D、评分、I/O 及调试 hook，生产选择/回填/同步保留。CUDA Event 是辅助 stream elapsed，不是纯 kernel 求和。

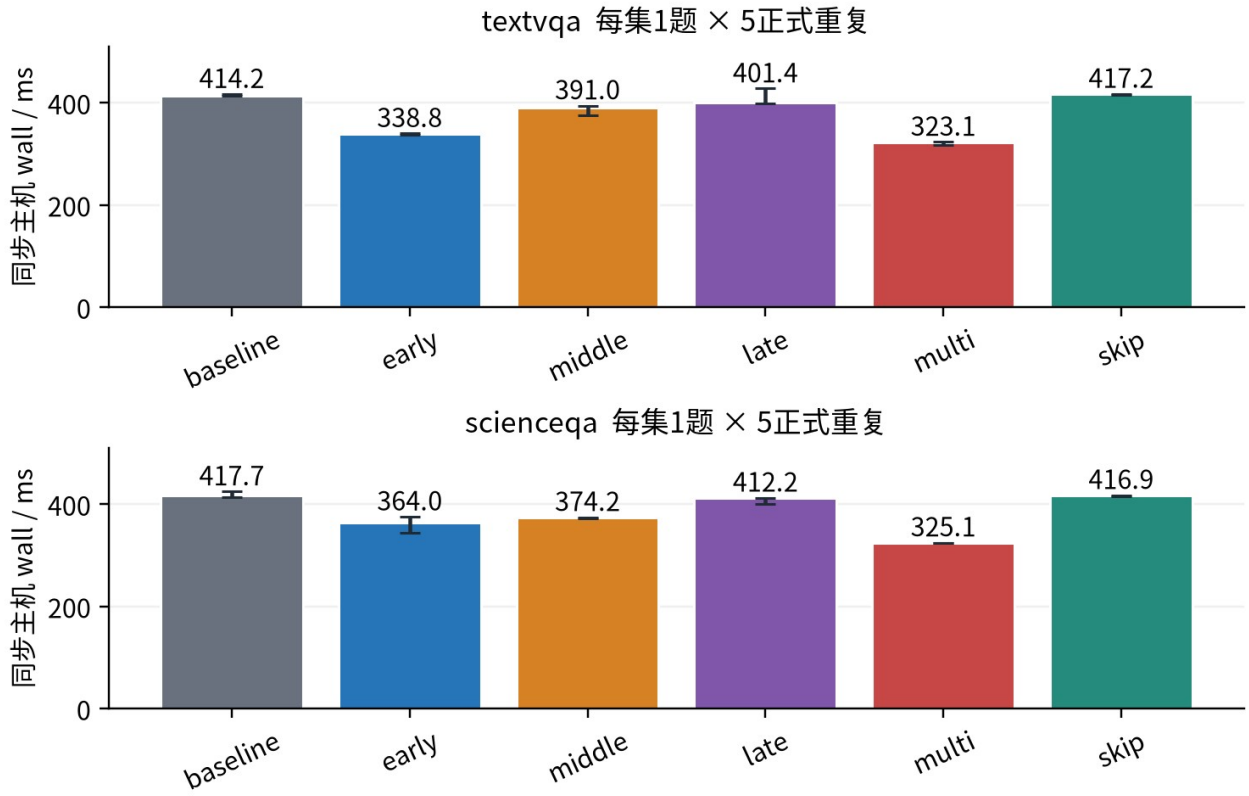



图 5 统一 G=16 后 Skip 几乎无速度收益。来源：cost-perf-v1 fixed16 原始测量，每集 n=1 题、2 预热 5 正式；柱为 median，误差端点为真实 Q1/Q3，单位 ms，不是置信区间。min=max_new_tokens16，文本不进入质量表。

两集 Skip 速度比 0.993×/1.002×；Early 为 1.223×/1.147×、Multi 为 1.282×/1.285×，伴随 § 5.1 的质量损失。完整首 token、fixed16 及自然延迟/实际 G/速度比在附录 D，不使用 v3 基线重算这些比例。

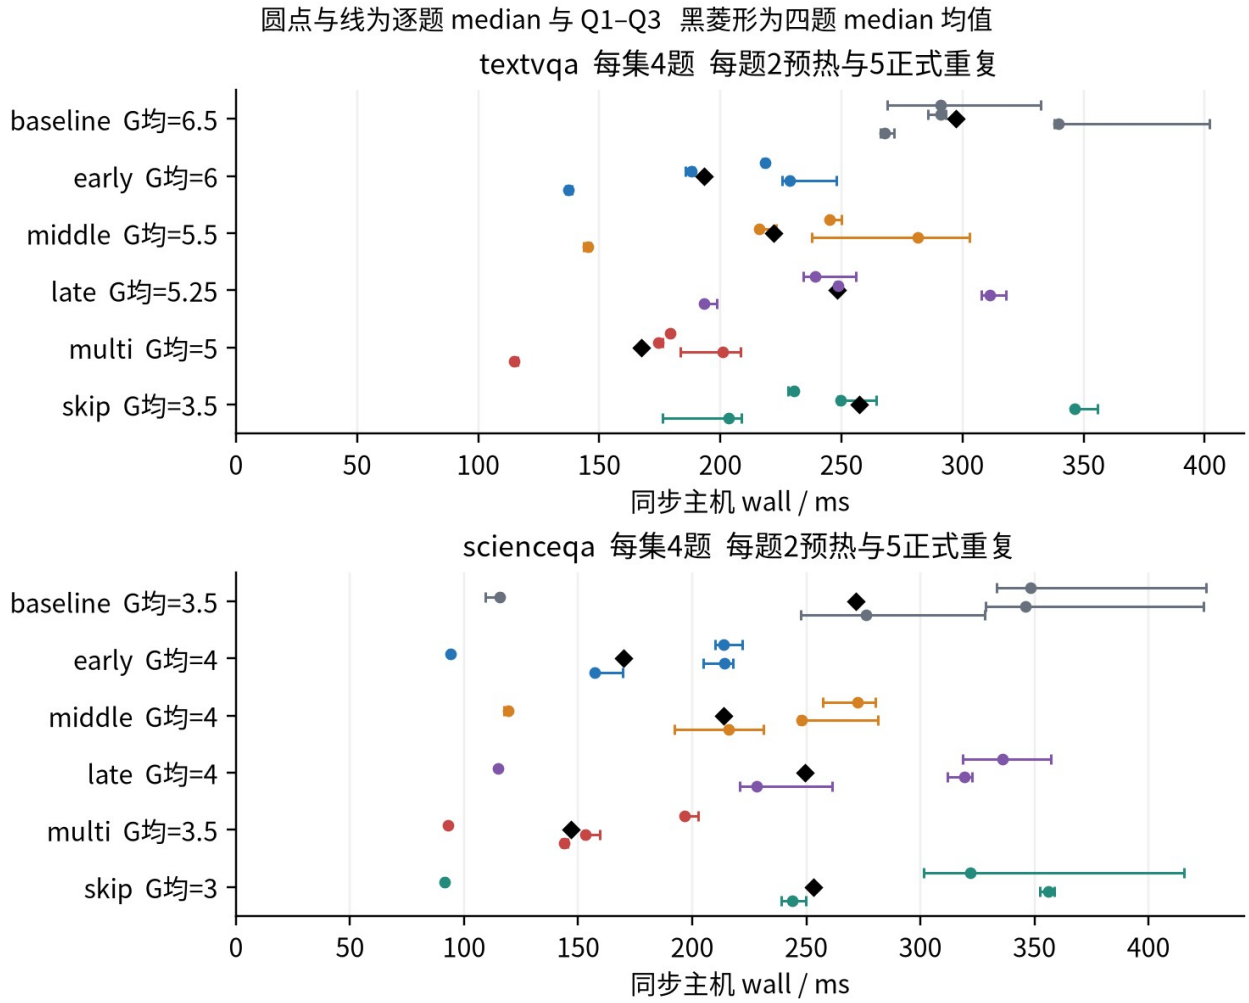



图 6 自然输出长度变化使 wall 加速不能等同同工作量加速。来源：cost-perf-v1 natural，每集 n=4 题、每题 2 预热 5 正式；圆点为各题 median，线为各题真实 Q1/Q3，黑菱形为四题 median 均值，单位 ms；G 均为四题实际生成长度均值，无总体置信区间。

例如 Text Skip 平均 G 由 6.5 降至 3.5，输出变短参与了自然延迟变化。allocated 峰值约 2902 MiB，剪枝略增、Skip 几乎相同；reserved 是分配器历史，不能代替活跃显存。旧锚点变化 Text−2.46%、Science+3.83%，未过 10%线，但未锁频、小 n 仍限制外推。

主要 FLOPs 不含排序、gather、回填、CPU 同步和框架调度全部开销。旧独立 Connector 回放剪枝约 4–5 ms、基线约 0.3–0.5 ms，给出适配开销的实测落点；这些独立 median 不能相加为端到端，也不能用总 wall 减 vision 推出 LLM 耗时。部分模块 median 顺序不符合包含关系，未用配对实验定位时钟/调度等原因。单步 decode 以 fresh prefill cache 和固定基线首 token 回放，wrapper 含位置/cache 张量构造。

# 6 正确性与真实执行

以下均为已保存的 context-v2/v3 实测证明，报告改版只读提取；有限固定样本不保证任意输入。

| 检查对象 | 对象与容差 | 保存结果 |
| --- | --- | --- |
| 单点 100%与 Multi 全 100% | Text5/Science2×4 模式；Encoder、postnorm、Connector、prefill logits；atol=rtol=0 | 32 张量最大绝对误差 0，完整生成 IDs 相等；score/scatter 调用 0 |
| 空 Skip | 两输入 prefill 及独立 cache 一步 decode 最后位置 logits；atol=rtol=0 | 最大误差 0，完整生成 IDs 相等 |
| 真实 50%与 Multi | 四配置各 4 真实样本，受控 mask/残差、24 真实 stage 独立重建选集 | FFN/后层短形状及矩阵见 § 2.4/附录 C |
| padding 与回填 | 有效[16,5]；postnorm 后原位置对齐 | 禁用 key 权重 109584 项最大 0；扰动 padding 不改有效输出；保留相等、丢弃精确 0 |
| 恢复与清理 | 全 named_modules 的 forward/hook、参数身份/指针/version | 正常退出与五配置受控异常恢复；未测任意 OOM/kill |

100%关闭额外路径走原生 bypass，只证明无压缩一致性，不检验真实 50%排序/gather；后者由独立受控数值、pre-hook 与矩阵支撑。Encoder 未单独比较 decode logits；空 Skip 则显式覆盖独立 cache 一步 decode。三层非空 Skip 执行证据见 § 4.4。

Git 中的 B2 proof_index 是导航摘录，不是完整证明。约 50 MB 完整 proof、全部 trace 与 3072 原子结果在科学附件；精选 JSON 和图源通过 E2–E7 定位。v3 保存 27 条命令 exit0、512 图 SHA、12 条严格重放与两套 3072 成本字节一致；新增 24 条另版验证薄入口，不扩充这里的主质量/主性能样本。

# 7 结论限制来源与复现

## 7.1 可以支持的结论和未验证范围

该适配真实减少 Encoder 内部张量和主要矩阵量，同机小基准中部分配置 wall 改善，代价是全部变体质量下降。Late 较少损失与较少成本节省、Multi 大幅损失，是固定协议下的观察，未证明最优层或质量损失的唯一机制。零网格保留了原 Connector/LLM 位置契约，权重存储未缩小；Skip 质量代价大，同长度速度收益不明确。早期密集 Attention 可能影响内存峰值，但没有独立分配时间线来证明原因。

范围只有一个 GPU、BF16、batch1、eager 及两固定 validation 子集。冷安装、冷模型/数据获取、跨机/其他 GPU/Windows/macOS、新入口完整 256、Flash/SDPA、v3 first/stages、严格 replay limit256 与任意 OOM/kill 未验证。未训练、扫参、追官方分数或为改报告追加实验；没有将新 24 调度时间当规范性能。

### 7.2 来源许可与 AI 实际贡献

模型、Processor、generate、Idefics3/Llama 模块直接复用 Transformers4.57.6；EncoderTopKPatch 和 SkipPatch 是固定源码的实例级适配。Text 评分原样复用 MMF，Science 指标参考官方实现、文本解析为本地适配。代码来源/固定 SHA/许可在来源与改动、NOTICE 逐项保留，混合工程未统一宣称 MIT/Apache。

AI 主要完成代码适配、实验编排、统计与自动核验，并完成薄入口、已执行 24 条小样本验证、报告正文/图注/图表/排版、导航和汇报准备。此次报告改版由 AI 自主写作、只读复算、渲染和发布。Sean-xzx 提供任务、约束、公开与范围决策；未声称其亲写原稿、人工逐题核验、已审阅或已独立掌握。技术交流准备材料不证明个人能力验收；教授指定现场环节可查代码文档，须本人独立完成、不用 AI/Agent。

实际自动检查包括原子分数重聚合、源 SHA 与矩阵/调用记录核对、Markdown/Word 同源构建及 PDF 逐页渲染。历史勘误/失败保留原结论，不修改原 hash 或绕 assert。

### 7.3 接收者的最短复现路线

从当前仓库取得 main；按复现命令页下载固定 postday3-v3 完整科学包、校 SHA、解包，准备固定依赖与模型缓存。单独 clone 不含全部图片与父证据。以下变量 U 为解包根，P 为固定依赖解释器，OUT 为包外全新输出根；安装与数据准备细节见命令页。

```
python3 -B scripts/check_repository.py --artifact-root "$U"
"$P" -B "$U/scripts/release_checks.py" --mode data --output-dir "$OUT/data"
"$P" -B scripts/evaluate_release.py --artifact-root "$U" \
  --configuration early --limit 2 --output-dir "$OUT/new-early"
"$P" -B "$U/scripts/release_checks.py" --mode correctness --output-dir "$OUT/check"
"$P" -B "$U/scripts/release_checks.py" --mode performance \
  --configuration baseline --phase fixed16 --output-dir "$OUT/perf"
"$P" -B "$U/scripts/release_checks.py" --mode profiler --output-dir "$OUT/profile"
"$P" -B "$U/scripts/analyze_costs.py" \
  --probe-root "$U/evidence/day2_evening/cost_perf_v1" --output-dir "$OUT/cost"
```

更换 configuration 遍历六配置。evaluate_release 复用原 loader、prompt、补丁、generate、评分和汇总，输出逐题 raw/IDs/score/parse/T/G 与绑定；history-compare 可选，仅诊断相等。已测六配置各两集前 2 题（Text5/19、Science2/9），共 24 条、无异常/解析失败，partial_mean_score 与完整 mean_score 隔离。完整 256 可传参但未实跑。严格逐字重放另用 U/scripts/replay_release.py，区别于新评估。

### 7.4 主要参考与报告版本

模型固定 revision；TextVQA 评分说明与 MMF 固定评分源码；ScienceQA 官方准确率定义；题目 Token 压缩参考仅供方法参考，未运行其音频框架。Projector 概念来源在 § 3。

本报告 professor-report-v2 与旧 Release autonomous-20261031-release 内 17 节报告不同；旧 tag/附件及其 SHA 回执保留历史。当前报告以 main/report 为入口，Word 由本 Markdown 生成，PDF 由 Word 同源导出。slides 保持旧版，尚未随本报告重制。实际下载/版本关系见 PUBLICATION。

# 附录 A 完整逐层 Token

每格为 Na/Nf，单位 token/图块；context-v2 Text row5、13 独立图块。baseline 与 Skip 视觉路径相同。单点出口 512，Multi 出口 128；回填发生于 Encoder 之后，不送回后层 Encoder。全两集 24576 条逐层原记录见 E3，图源为 layer_tokens.csv。

| 层 | baseline 及 skip | early | middle | late | multi |
|---|---|---|---|---|---|
| 1 | 1024/1024 | 1024/1024 | 1024/1024 | 1024/1024 | 1024/1024 |
| 2 | 1024/1024 | 1024/1024 | 1024/1024 | 1024/1024 | 1024/1024 |
| 3 | 1024/1024 | 1024/512 | 1024/1024 | 1024/1024 | 1024/512 |
| 4 | 1024/1024 | 512/512 | 1024/1024 | 1024/1024 | 512/512 |
| 5 | 1024/1024 | 512/512 | 1024/1024 | 1024/1024 | 512/512 |
| 6 | 1024/1024 | 512/512 | 1024/512 | 1024/1024 | 512/256 |
| 7 | 1024/1024 | 512/512 | 512/512 | 1024/1024 | 256/256 |
| 8 | 1024/1024 | 512/512 | 512/512 | 1024/1024 | 256/256 |
| 9 | 1024/1024 | 512/512 | 512/512 | 1024/512 | 256/128 |
| 10 | 1024/1024 | 512/512 | 512/512 | 512/512 | 128/128 |
| 11 | 1024/1024 | 512/512 | 512/512 | 512/512 | 128/128 |
| 12 | 1024/1024 | 512/512 | 512/512 | 512/512 | 128/128 |

# 附录 B FLOPs 推导与分项

## B1 计数范围和公式

符号：图块数 B、N0=1024、视觉 dv=768/mv=3072/H=12；LLM d=576/m=1536、30 层、9Q/3KV、head 维 64、d_kv=192、词表 V=49280。Na/Nf 使用附录 A 各层实际物理长度，正式 padding0。FMA 计 2；矩阵总数不等于硬件指令实测。

| 部分 | 主要 FLOPs 与推导 |
|---|---|
| patch 卷积 | $2BN0(3\times16^2)dv$ |

| 部分 | 主要 FLOPs 与推导 |
| --- | --- |
| 视觉 QKV/O | 4 个 dv×dv 投影：$8BNa\ dv^2$ |
| 视觉 QK/AV | 两次 Attention 矩阵乘法：$4BNa^2dv$ |
| 视觉 fc1/fc2 | 两次矩阵乘法：4BNf dv mv |
| 原 Connector | 2B×64×12288×576 |
| LLM 每层 GQA 投影 | Q/O 宽 d、K/V 宽 d_kv：4qd(d+d_kv) |
| LLM 每层 QK/AV | 4qsd，s 为含当前输入的 KV 长度 |
| LLM 每层 gated FFN | 3 个矩阵：6qdm；基线 30 层、Skip27 层 |
| 输出头每调用 | 2×1×d×V；只处理最后位置 |
| 合计 | patch + Σ 视觉层 + Connector + LLM prefill + Σdecode + G 个输出头 |

prefill 令 q=s=T；decode 第 j 步（j=1…G−1）令 q=1、s=T+j。n=G−1，则 decode 的 Σs=nT+n(n+1)/2。视觉与 Connector 仅 prefill 一次；完整 G 输出共 G 次头调用。Skip 减少的三层 FFN 如 § 4.3，norm2 辅助运算另列。每题 B/T/G 不同，先按原子记录算再汇总，不能用平均 T 代入 $T^2$。

### B2 实际 G 下全 256 题均值

下面每格单位 GFLOPs/题；视觉含 patch，LLM prefill/decode 均不含输出头。原 costs_actual_G.csv 每配置/数据集 256 行，实际 G 不强制相同。统一 G*=16 总量见 § 5.2，完整两模式均值/范围在 costs.csv 和 ranges.csv。

TextVQA：

| 配置 | 视觉含 patch | Connector | prefill | decode | head | 合计 |
| --- | --- | --- | --- | --- | --- | --- |
| baseline | 2919.83 | 12.37 | 258.48 | 1.18 | 0.30 | 3192.16 |
| early | 1666.12 | 12.37 | 258.48 | 1.19 | 0.30 | 1938.46 |
| middle | 2062.02 | 12.37 | 258.48 | 1.14 | 0.29 | 2334.32 |
| late | 2457.93 | 12.37 | 258.48 | 1.32 | 0.33 | 2730.43 |
| multi | 1189.79 | 12.37 | 258.48 | 1.47 | 0.36 | 1462.48 |
| skip | 2919.83 | 12.37 | 243.65 | 1.28 | 0.34 | 3177.47 |

ScienceQA-IMG:

| 配置 | 视觉含 patch | Connector | prefill | decode | head | 合计 |
|---|---|---|---|---|---|---|
| baseline | 3003.35 | 12.73 | 288.42 | 0.98 | 0.26 | 3305.73 |
| early | 1713.77 | 12.73 | 288.42 | 0.82 | 0.22 | 2015.96 |
| middle | 2121.01 | 12.73 | 288.42 | 0.83 | 0.22 | 2423.20 |
| late | 2528.24 | 12.73 | 288.42 | 0.91 | 0.24 | 2830.54 |
| multi | 1223.82 | 12.73 | 288.42 | 0.88 | 0.23 | 1526.08 |
| skip | 3003.35 | 12.73 | 272.34 | 0.98 | 0.27 | 3289.65 |

### B3 额外开销如何记录

FP32 score 以 $BN^2(H+2)$基本算术单列；Attention cast 每元素 BF16 读 2 bytes、FP32 写 4 bytes；每阶段每块 3 次 stable argsort。成本 CSV 另存 GELU/SiLU 次数、bias 加法、gated 逐元素乘、RMS 基本算术/rsqrt、dense softmax exp 计数。vision_gelu=BΣNf mv，LLM gated 乘与 SiLU 各 =active(T+G−1)m；RMS 行数=(30+active+1)(T+G−1)，每行基本算术按 4d+1 计，active=30 或 27。

bias、norm、激活、softmax、rope、mask、查表、比较/排序、guards、gather/scatter、CPU 循环/同步、KV 移动、采样控制、预处理/H2D/I/O 均不并入主要矩阵总数；辅助计数也不冒称硬件 FLOPs。完整字段约定见 components 和 E6；这些开销保留于相应生产计时边界内（预处理/H2D 等明确排除项除外）。

## 附录 C 实际矩阵与 pre-hook 明细

### C1 当前与后层 FFN

context-v2 B4 Text row5，B=13、T=889、单次诊断 prefill。表为 fc1 与 fc2 的实际 addmm 输入形状、CPU 总区间及关联 CUDA 时间（µs）；不相加、不作规范速度比。矩阵时间取同一个 operator 条目，无嵌套 marker 求和。fc1 pre-hook=[13,K,768]，fc2 pre-hook=[13,K,3072]，K 由各行矩阵首维/13 得到。基线 K=1024。下面列出所有剪枝当层与下一层，并含基线 3/6/9 层。

| 配置/层/模块 | pre-hook | 矩阵 A × B | CPU µs | CUDA µs |
|---|---|---|---|---|
| baseline L3 fc1 | [13,1024,768] | [[13312,768],[768,3072]] | 31.26 | 986.68 |
| baseline L3 fc2 | [13,1024,3072] | [[13312,3072],[3072,768]] | 29.71 | 926.78 |
| baseline L6 fc1 | [13,1024,768] | [[13312,768],[768,3072]] | 31.52 | 1047.13 |
| baseline L6 fc2 | [13,1024,3072] | [[13312,3072],[3072,768]] | 29.94 | 982.17 |

| 配置/层/模块 | pre-hook | 矩阵 A × B | CPU μs | CUDA μs |
|---|---|---|---|---|
| baseline L9 fc1 | [13,1024,768] | [[13312,768],[768,3072]] | 30.63 | 1051.00 |
| baseline L9 fc2 | [13,1024,3072] | [[13312,3072],[3072,768]] | 29.27 | 985.85 |
| early L3 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 49.42 | 450.59 |
| early L3 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 33.90 | 414.59 |
| early L4 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 31.16 | 449.24 |
| early L4 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 30.13 | 414.53 |
| middle L6 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 68.00 | 527.58 |
| middle L6 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 36.73 | 494.30 |
| middle L7 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 32.56 | 526.72 |
| middle L7 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 30.88 | 493.60 |
| late L9 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 105.30 | 446.30 |
| late L9 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 45.39 | 407.96 |
| late L10 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 48.64 | 443.07 |
| late L10 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 34.20 | 409.31 |
| multi L3 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 110.10 | 458.17 |
| multi L3 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 54.32 | 421.50 |
| multi L4 fc1 | [13,512,768] | [[6656,768],[768,3072]] | 50.16 | 455.80 |
| multi L4 fc2 | [13,512,3072] | [[6656,3072],[3072,768]] | 36.48 | 422.24 |
| multi L6 fc1 | [13,256,768] | [[3328,768],[768,3072]] | 46.99 | 209.70 |
| multi L6 fc2 | [13,256,3072] | [[3328,3072],[3072,768]] | 35.62 | 188.99 |
| multi L7 fc1 | [13,256,768] | [[3328,768],[768,3072]] | 32.46 | 205.31 |
| multi L7 fc2 | [13,256,3072] | [[3328,3072],[3072,768]] | 55.58 | 189.41 |
| multi L9 fc1 | [13,128,768] | [[1664,768],[768,3072]] | 46.56 | 109.57 |
| multi L9 fc2 | [13,128,3072] | [[1664,3072],[3072,768]] | 35.34 | 98.24 |
| multi L10 fc1 | [13,128,768] | [[1664,768],[768,3072]] | 43.11 | 106.62 |
| multi L10 fc2 | [13,128,3072] | [[1664,3072],[3072,768]] | 33.25 | 96.51 |

### C2 Multi 三次剪枝后的 Attention

L4/L7/L10 分别承接 L3/L6/L9 缩短结果。下表列 q_proj 及 QK/AV bmm，K=512/256/128；每块 12 头，所以展平 B×H=156。q_proj pre-hook=[13,K,768]；矩阵 A/B 均为原 profiler 输入，时间为 µs。三阶段当前 FFN 已在 C1 覆盖，不能只看最后一次。

| 层与算子 | 矩阵输入 A / B | CPU µs | CUDA µs |
|---|---|---|---|
| L4 q_proj | [[6656,768],[768,768]] | 39.47 | 116.93 |
| L4 QK | [[156,512,64],[156,64,512]] | 27.13 | 246.43 |
| L4 AV | [[156,512,512],[156,512,64]] | 27.25 | 215.55 |
| L7 q_proj | [[3328,768],[768,768]] | 53.44 | 59.14 |
| L7 QK | [[156,256,64],[156,64,256]] | 27.11 | 50.62 |
| L7 AV | [[156,256,256],[156,256,64]] | 24.58 | 42.85 |
| L10 q_proj | [[1664,768],[768,768]] | 42.19 | 34.27 |
| L10 QK | [[156,128,64],[156,64,128]] | 28.32 | 14.14 |
| L10 AV | [[156,128,128],[156,128,64]] | 24.86 | 12.70 |

原 JSON 的 module_input_shapes、matrix_operators、marker_times 与 trace_sha256 对应 E3；完整 12 层 QKV/O、QK/AV、fc1/fc2 和 score/select/scatter 区间在科学包 B4 原件，Git 精选 JSON 可直接检查。

## 附录 D 统计范围与科学版本

### D1 正式质量的实际 G 和截断

每组 256 题，G 为新 token 数（含停止 token，依保存 generate 记录），表内为均值与 min–max；截断列为 Text/Science 可能截断数。失败保留分母。

| 配置 | Text G 均值与范围 | Science G 均值与范围 | 截断 T/S |
|---|---|---|---|
| baseline | 5.273 [3,16] | 4.500 [2,64] | 0/1 |
| early | 5.309 [3,15] | 3.914 [2,12] | 0/0 |
| middle | 5.133 [2,18] | 3.938 [2,26] | 0/0 |
| late | 5.754 [2,64] | 4.250 [2,33] | 2/0 |
| multi | 6.316 [2,64] | 4.082 [2,64] | 5/2 |
| skip | 5.906 [3,64] | 4.688 [2,64] | 2/2 |

基线 256 题范围：Text B=9–17、T=622–1163、G=3–16、全模型实际 G 成本 2092.5–3991.7 GF；Science B=5–17、T=379–1394、G=2–64、1164.3–4081.6 GF。各配置完整范围在 ranges.csv。代表题 shape 见 § 2.5，不能将其 13 块/832 位置当全数据常数。

### D2 cost perf v1 主性能精确表

T/S 为两数据集。natural/first 为 4 道题各 5 重复 median 的算术均值；fixed16 为 1 道题 5 重复 median。速度比=同数据集同 phase 基线 wall/变体 wall，单位 ms。natural 实际 G 单列，first 的 G=1、fixed16 的 G=16；逐题 Q1/Q3 见 performance_samples.csv 和图 5/6。

| 数据/配置 | natural ms | 自然速度比 | 实际 G 均值 | first ms | fixed16 ms / 速度比 |
|---|---|---|---|---|---|
| T / baseline | 297.235 | 1.000× | 6.5 | 219.35 | 414.22 / 1.000× |
| T / early | 193.208 | 1.538× | 6 | 118.47 | 338.77 / 1.223× |
| T / middle | 221.912 | 1.339× | 5.5 | 156.62 | 391.04 / 1.059× |
| T / late | 248.093 | 1.198× | 5.25 | 182.99 | 401.35 / 1.032× |
| T / multi | 167.404 | 1.776× | 5 | 104.65 | 323.14 / 1.282× |
| T / skip | 257.427 | 1.155× | 3.5 | 221.71 | 417.23 / 0.993× |
| S / baseline | 271.576 | 1.000× | 3.5 | 236.52 | 417.66 / 1.000× |
| S / early | 169.816 | 1.599× | 4 | 129.78 | 364.02 / 1.147× |
| S / middle | 213.897 | 1.270× | 4 | 169.30 | 374.21 / 1.116× |
| S / late | 249.613 | 1.088× | 4 | 193.59 | 412.21 / 1.013× |
| S / multi | 146.713 | 1.851× | 3.5 | 110.84 | 325.15 / 1.285× |
| S / skip | 253.235 | 1.072× | 3 | 235.76 | 416.89 / 1.002× |

### D3 不同版本各证明什么

| 科学版本与用途 | 实际范围 | 与主表关系 |
| --- | --- | --- |
| context-v2 正式质量 | 六配置×两集×256=3072；无执行异常 | §5.1 唯一正式质量来源 |
| cost-perf-v1 主性能 | 780 正式/312 预热；锚点另 20 正式；natural/first 每集 4 题、fixed16/stages 每集 1 题 | §5.3 与 D2；每题 2 预热 5 正式，不把重复当独立题 |
| postday3-v3 迁移 | 同机独立解包 27 命令；性能 120 正式/48 预热、锚点另 20/8；每集 1 题 natural/fixed16 | 独立迁移诊断，不混主表毫秒；锚点 −1.5501%/−1.1601% |
| 20261031 薄入口 24 条 | 六配置串行进程，Text5/19、Science2/9；历史字段相等，无异常/解析失败 | 仅 partial 验证；不替换 3072、不作规范性能 |
| professor-report-v2 | 只读提取、重画、写作、渲染、导航与发布 | 没有新模型前向或科学实验 |

v3 验证共享原解释器/GPU/HF 热缓存，不是独立安装或跨机。CPU 两套成本重算与原表字节相同，不是新预测。科学包 455733348 bytes，SHA256 为 d95a7774653f0b35f5e7cb37619807c27b0d295e0494d29b90b4be22bcec0d4d；它绑定旧科学资产，不绑定新版报告。

## 附录 E 教授原文覆盖索引

此表定位报告内的实质答案；仓库 67 项详细映射另给代码行和 E 证据。原文逐字副本为验收规格。

| 原文检查项 | 本报告位置 | 实现或证据 |
| --- | --- | --- |
| §1 模型/数据/抽样/预处理/prompt/生成/评分 | §1.1–1.2；D1 | 协议、manifest/meta、MMF/本地解析；E1/E5 |
| A 算法、四配置、取整/图块适配 | §2.1、图 1、附录 A | encoder_topk.py；E2/E3 |
| A 必答 1 参数/权重/逐层 Token | §2.2、图 2、附录 A | layer_tokens.csv；E1/E3 |
| A 必答 2 Encoder/全模型 FLOPs 与额外开销 | §2.3、§5.2、附录 B | analyze_costs.py；E6 |
| A 必答 3 当前 FFN/后层 pre-hook 及矩阵 shape/time | §2.4、附录 C1/C2 | 五配置 B4、Multi 三阶段及后层；E3 |
| A 必答 4 视觉到 Projector 到 LLM | §2.5、图 1 | 原 Connector 与零网格，832 代表题；E3 |

| 原文检查项 | 本报告位置 | 实现或证据 |
| --- | --- | --- |
| B 四类映射/Token 影响与实际模块 | §3、§2.5 | SimpleMLP 单 Linear 与 pixel shuffle；E3 |
| C 配置三层、选层理由、残差/norm | §4.1、图 1 | ffn_skip.py；E4 |
| C 必答 1 实际存储/FFN 停用参数 | §4.2、§2.2 | sum(p.numel())与权重文件；E4 |
| C 必答 2 FLOPs/prefill/decode/T/G | §4.3、附录 B/D | 15925248(T+G−1)；E6 |
| C 必答 3 模块调用与 profiler | §4.4 | 两阶段 L8/16/24 计数与投影缺席；E4/E7 |
| §5 六配置 12 组及 100%/空 Skip 误差 | §1、§2.1、§5.1、§6 | atol/rtol0 与真实 50%分开；E1/E2 |
| §5 同环境、计时边界/n/重复/同步/G 与理论差异 | §1.1、§5.3、D2/D3 | cost-perf-v1 主性能；E6/E7 |
| §6 源码/配置/结果/证据/复现命令 | §2–6、§7.3、附录 A–D | 当前 Git 精选+完整科学包；E1–E8 |
| §7 开源/AI/核验与个人技术交流 | §7.2、§7.4 | 许可原样保留；个人掌握/未来现场环节未验收 |