SmolVLM 无需训练压缩

视觉 Token 剪枝与 FFN Skip 的实验比较

Sean-xzx （GitHub 账号）

3072

正式预测 六配置 两集各 256 题

Encoder 减少计算，质量全部下降

原权重保留 质量与计算量分别核验

固定协议与两个评分对象

同题同输入 BF16 eager batch 1

TextVQA： 十参考留一软分

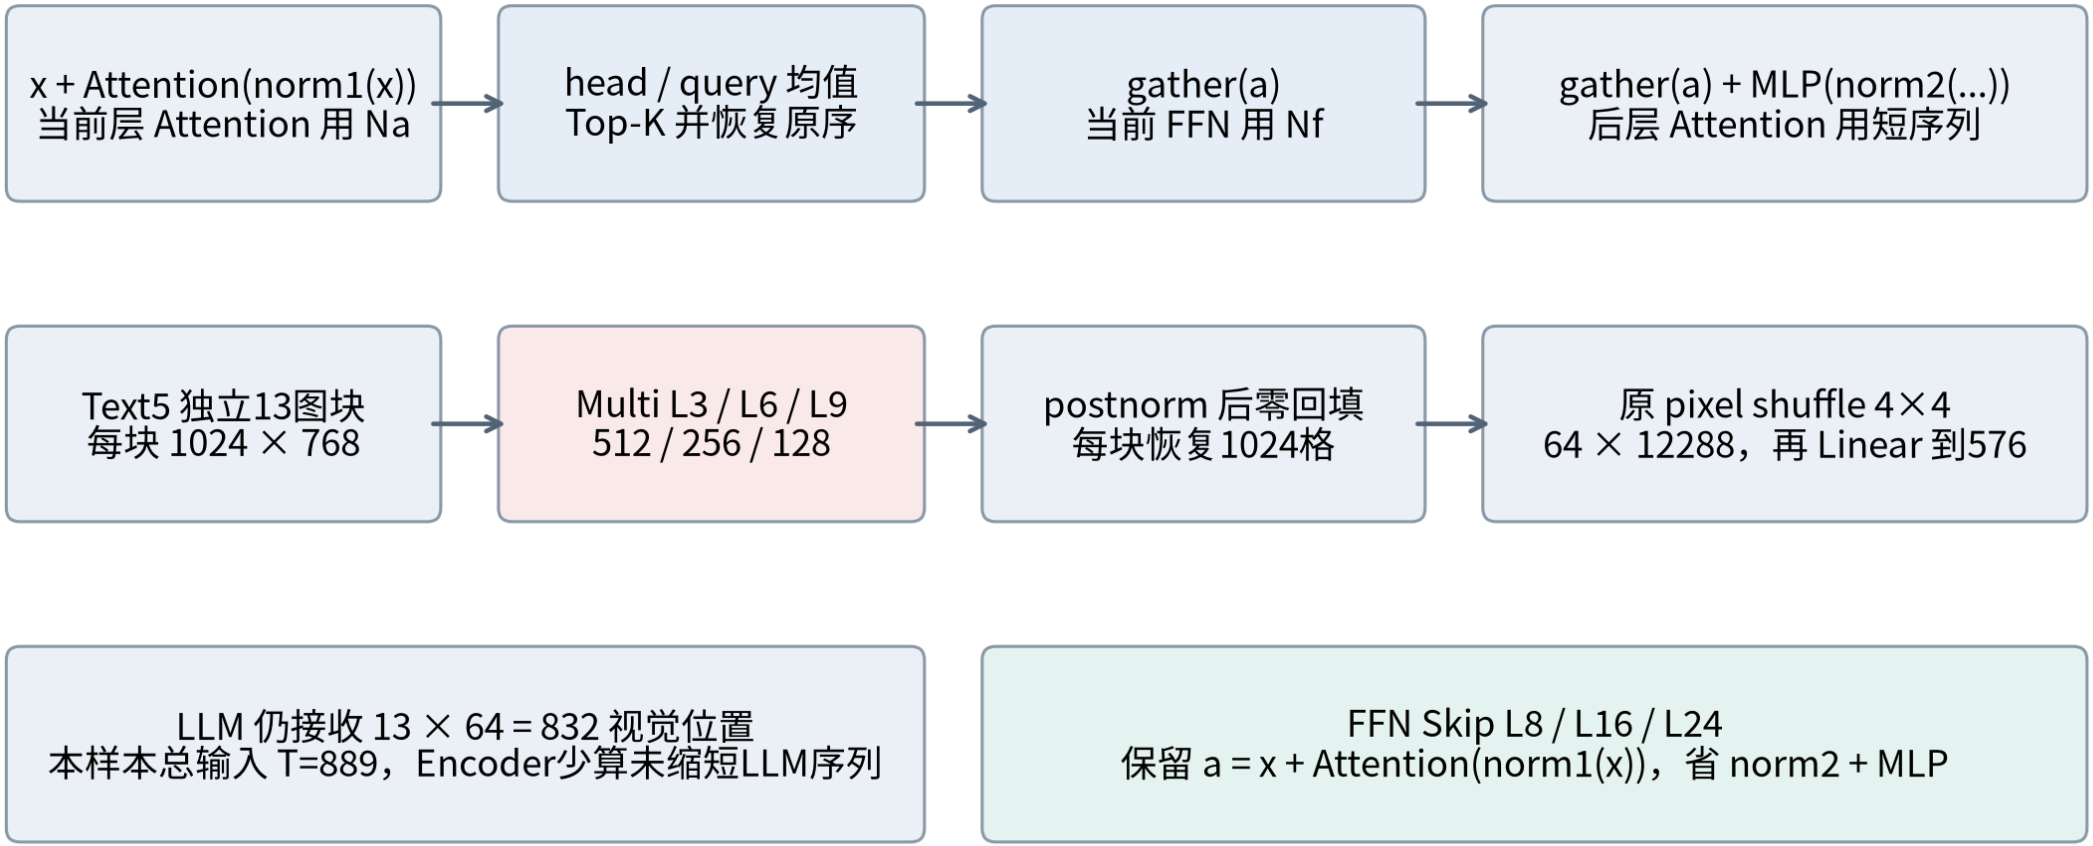
ScienceQA： 选项索引准确率 + 本地标签盲解析

Science 合法 hint 进入输入，答案与解析字段不进入

解析失败记 0 并保留分母

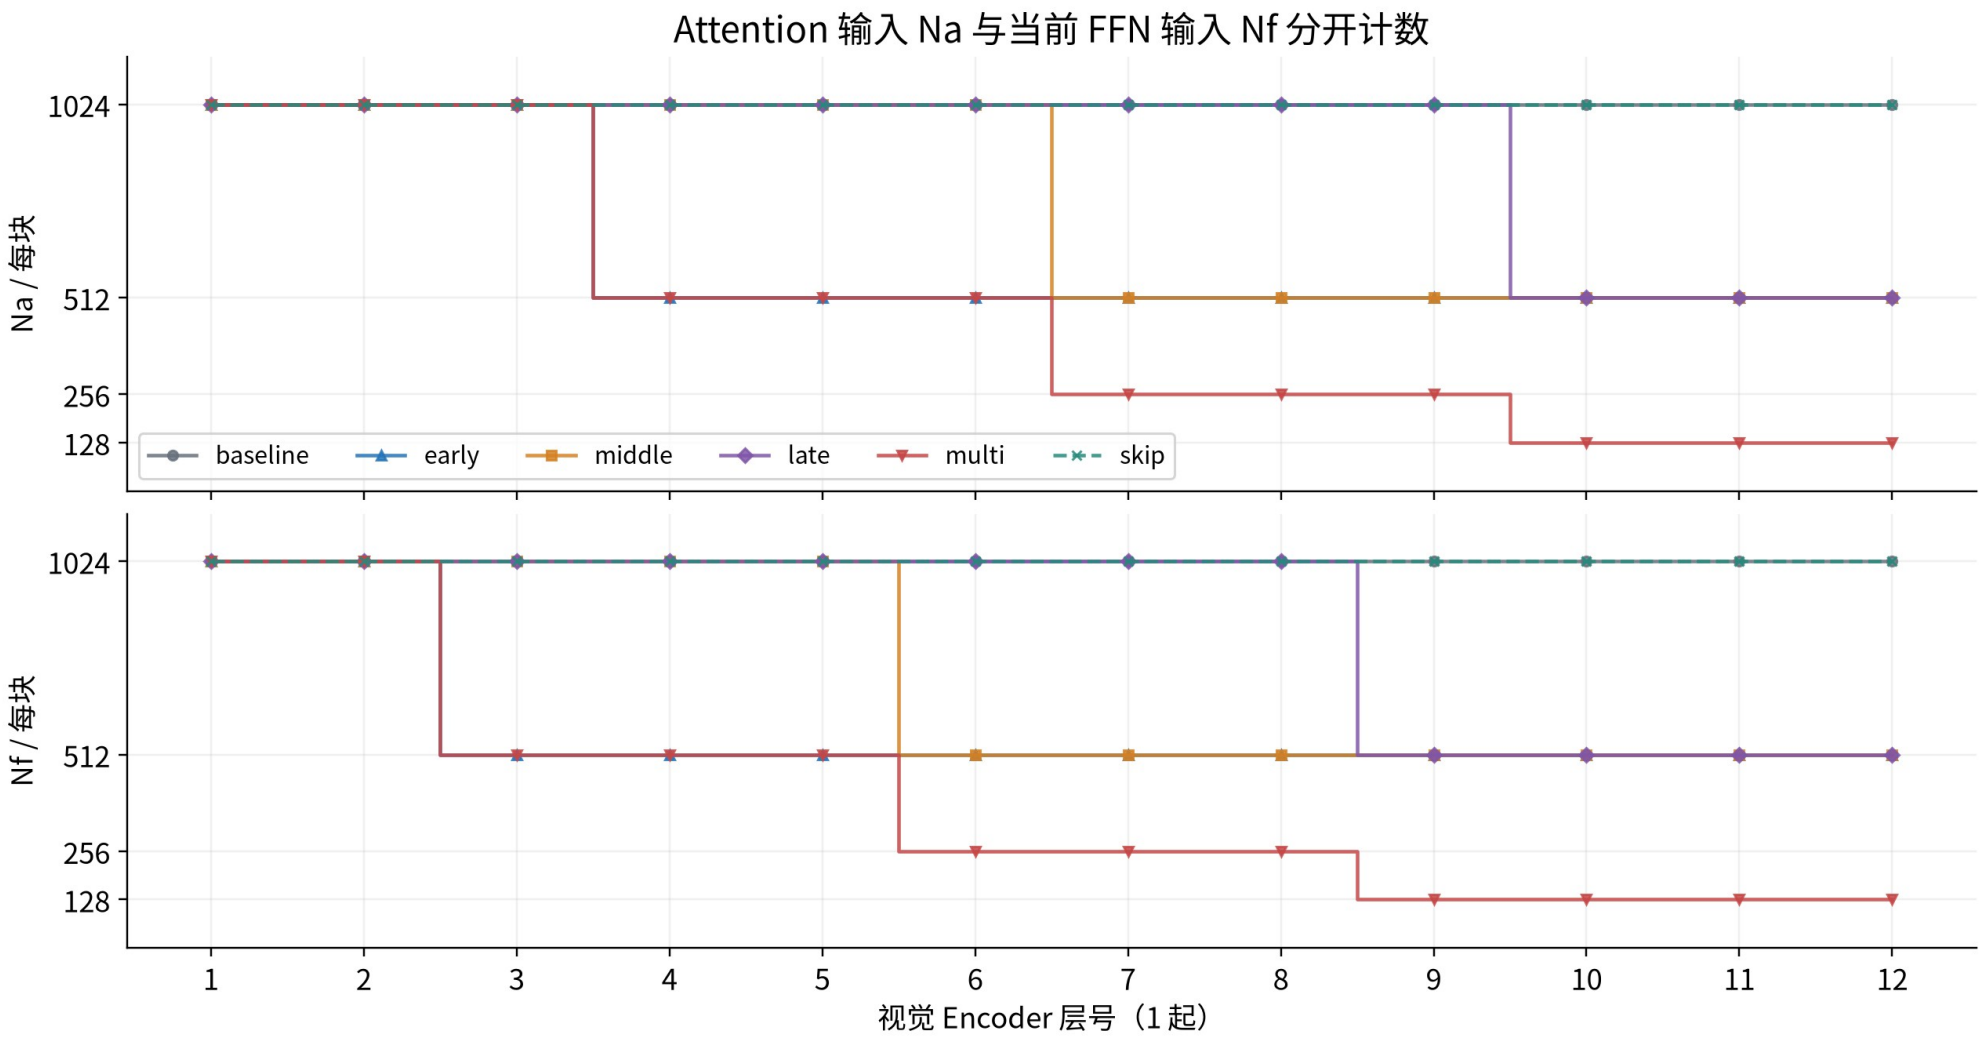
Encoder Top K 计算位置

Encoder Top-K 与原 Connector 的真实传播



Attention 残差后选择

Attention 与 FFN 的逐层长度



Na 为 Attention 输入， Nf 为当前 FFN 输入

Connector 适配与三层 FFN Skip

视觉传播

postnorm 后零回填
每块恢复 1024 格

pixel shuffle 4×4
单 Linear 12288 到 576

Text5 仍为 832 视觉位置

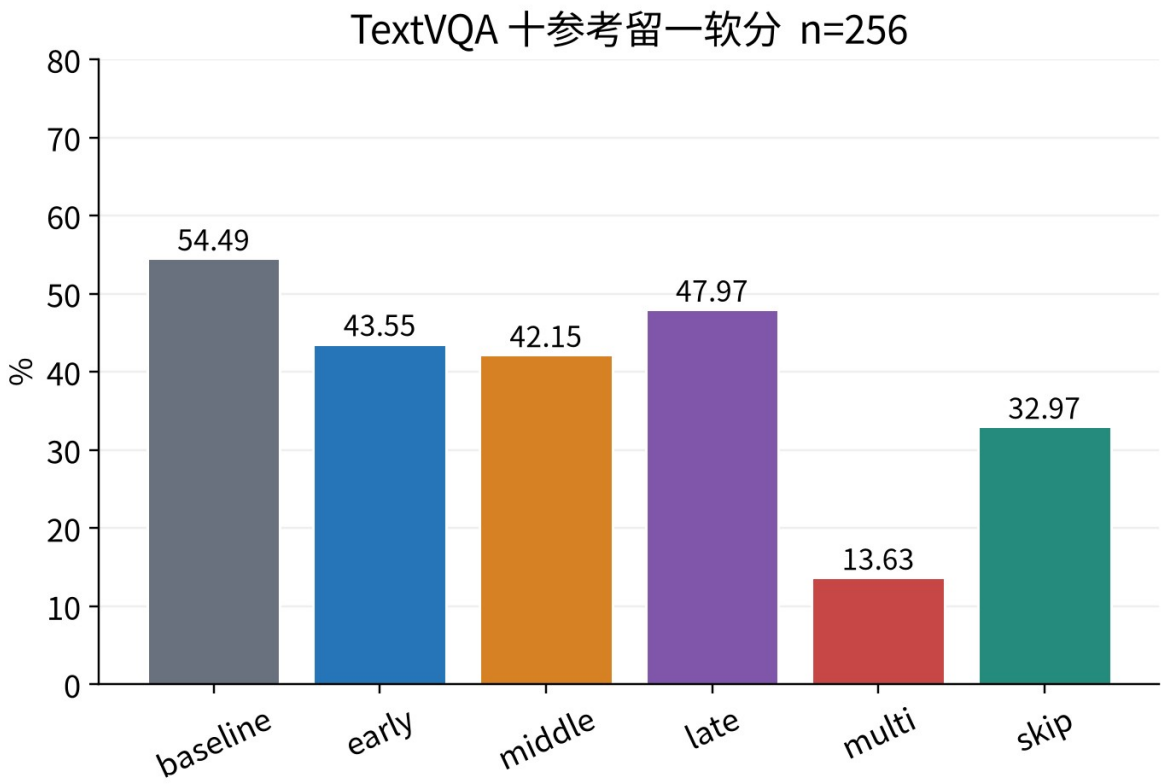
LLM FFN Skip

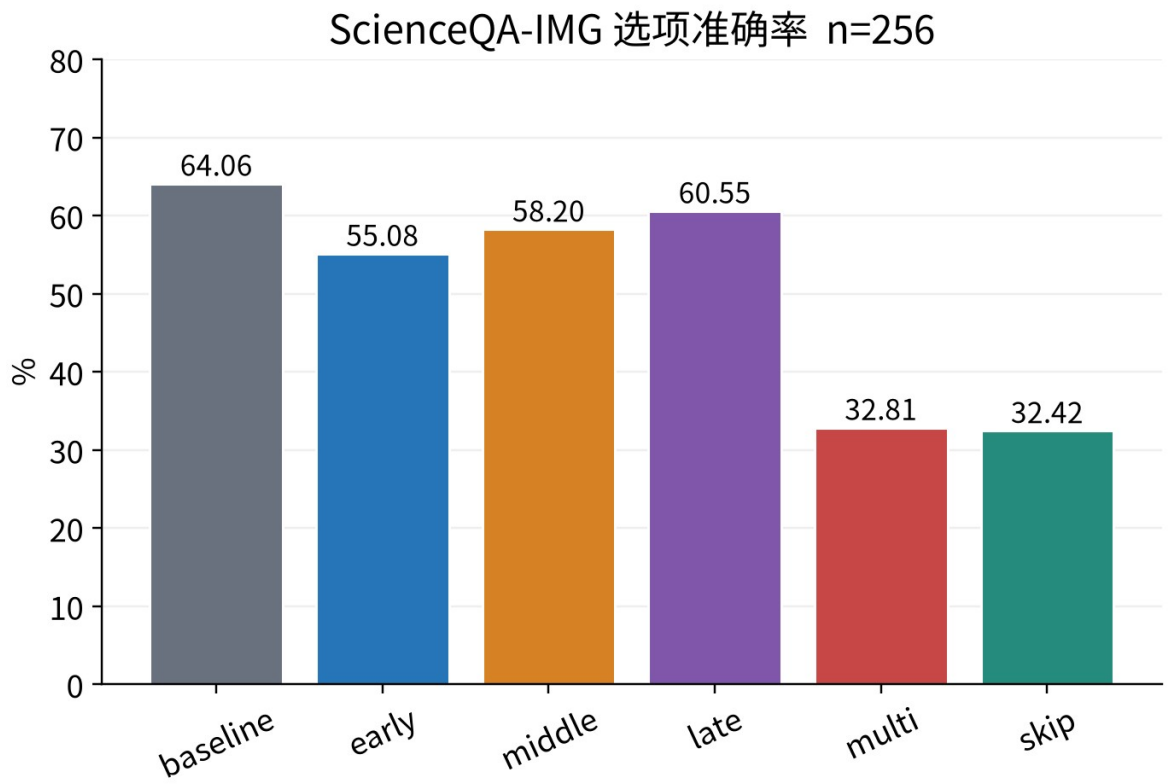
L8 / L16 / L24 同时跳过
保留 Attention 与 cache
省 norm2 + MLP

7962624 个 MLP 参数停用
另 norm2 为 1728
原权重仍全部保存

Linear 与 pointwise MLP 通常保持 N， Q-Former/Resampler 由 query/latent 数决定

正式质量结果与负结果

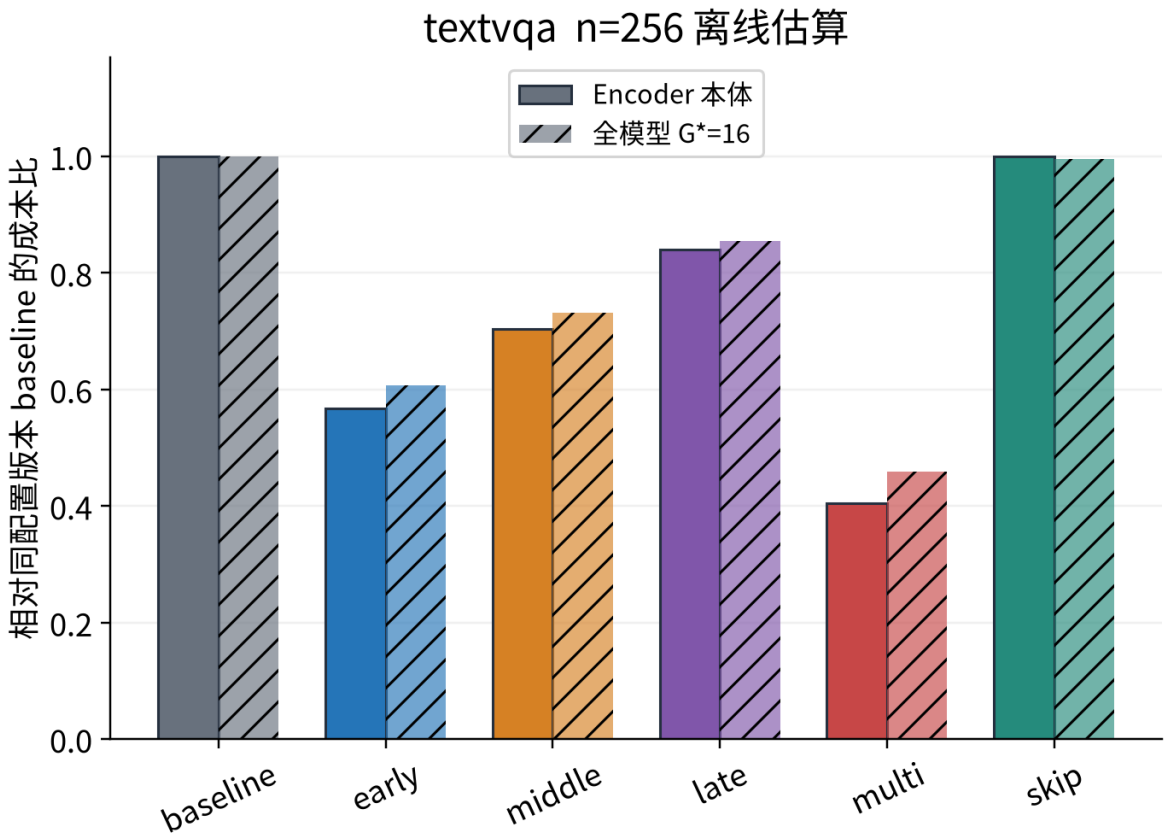


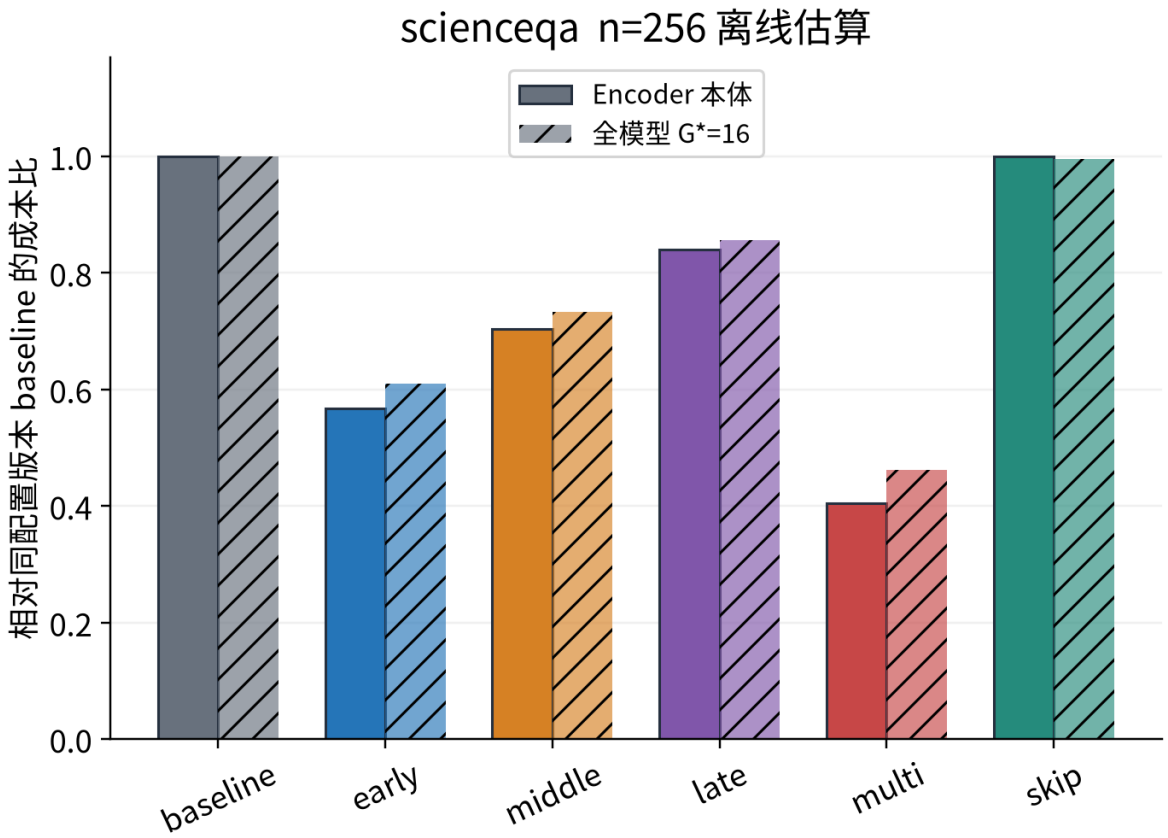


每组 n=256， Text 软分与 Science 准确率分别报告

Late 损失相对较小， Multi 与 Skip 损失很大

Encoder 成本与全模型成本

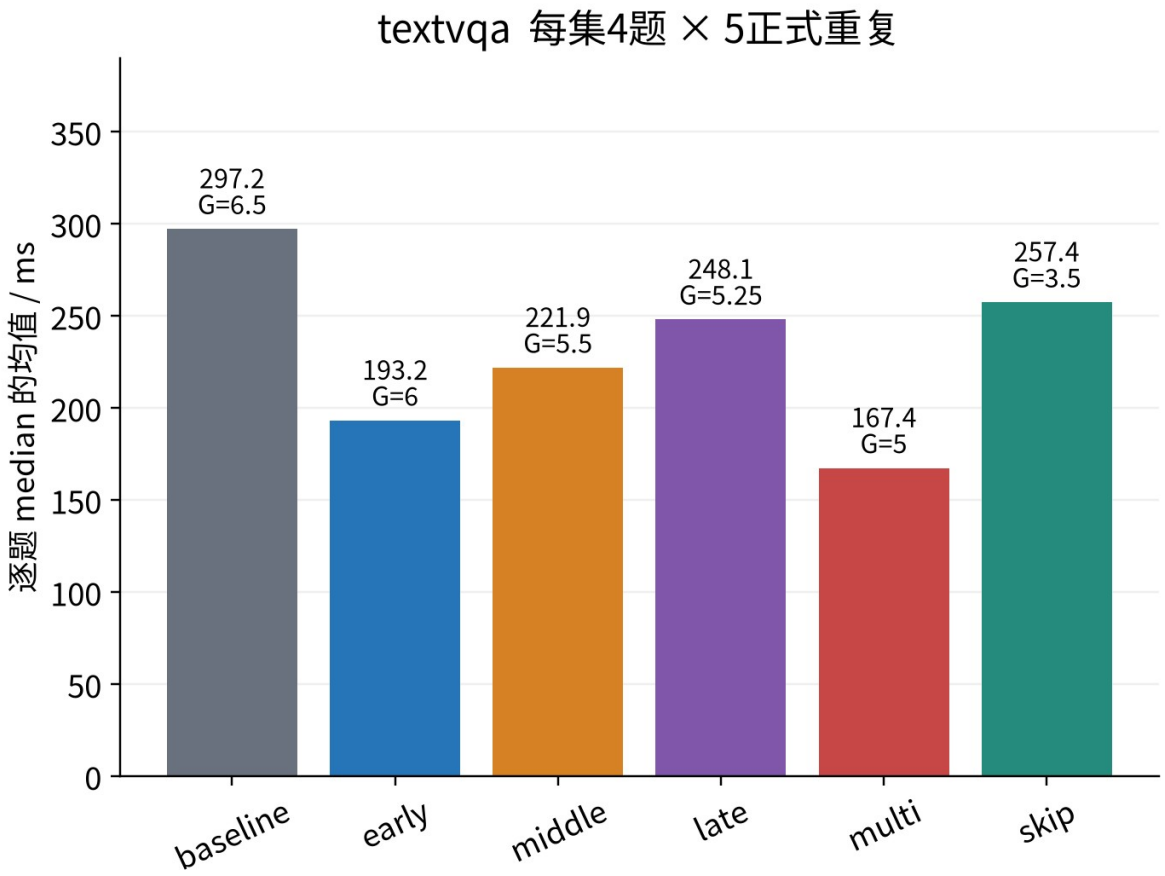


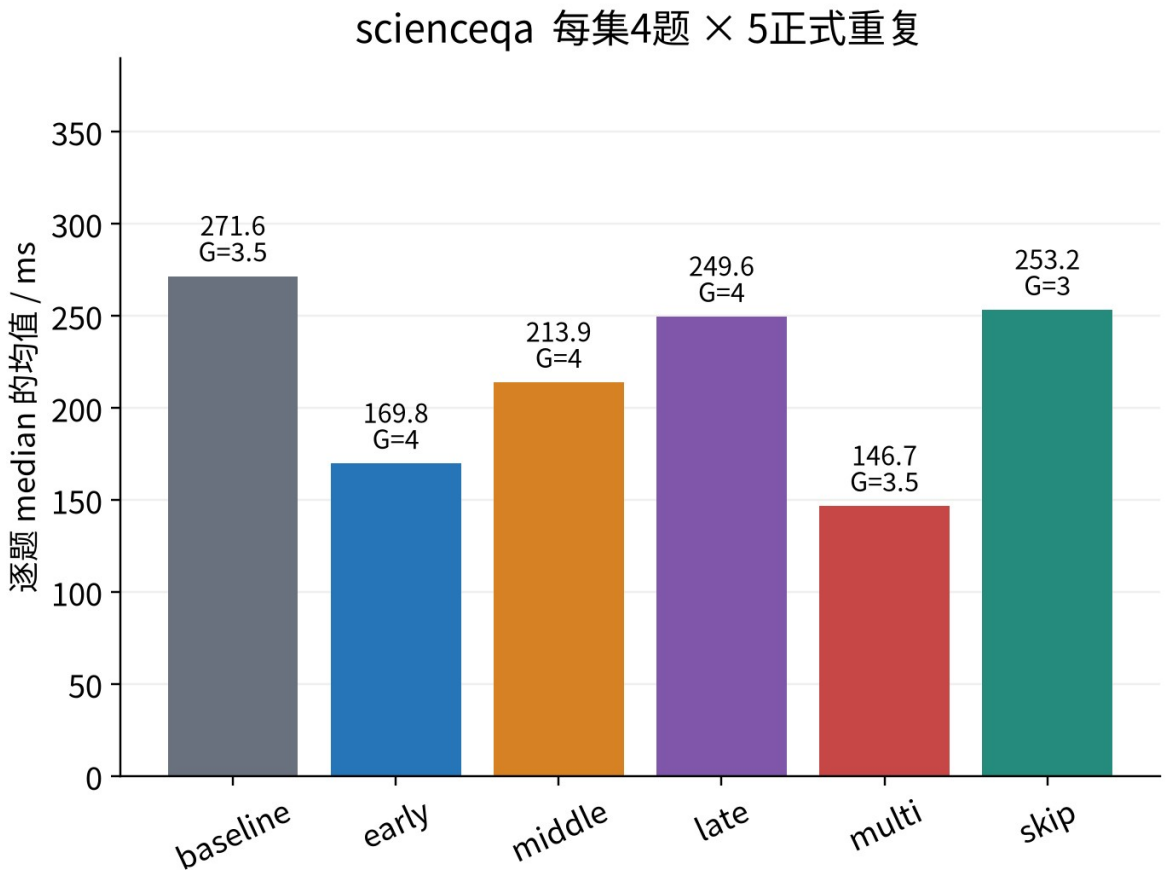


主要矩阵与卷积，乘加计 2

G*=16 是离线统一工作量估算

自然生成速度与输出长度

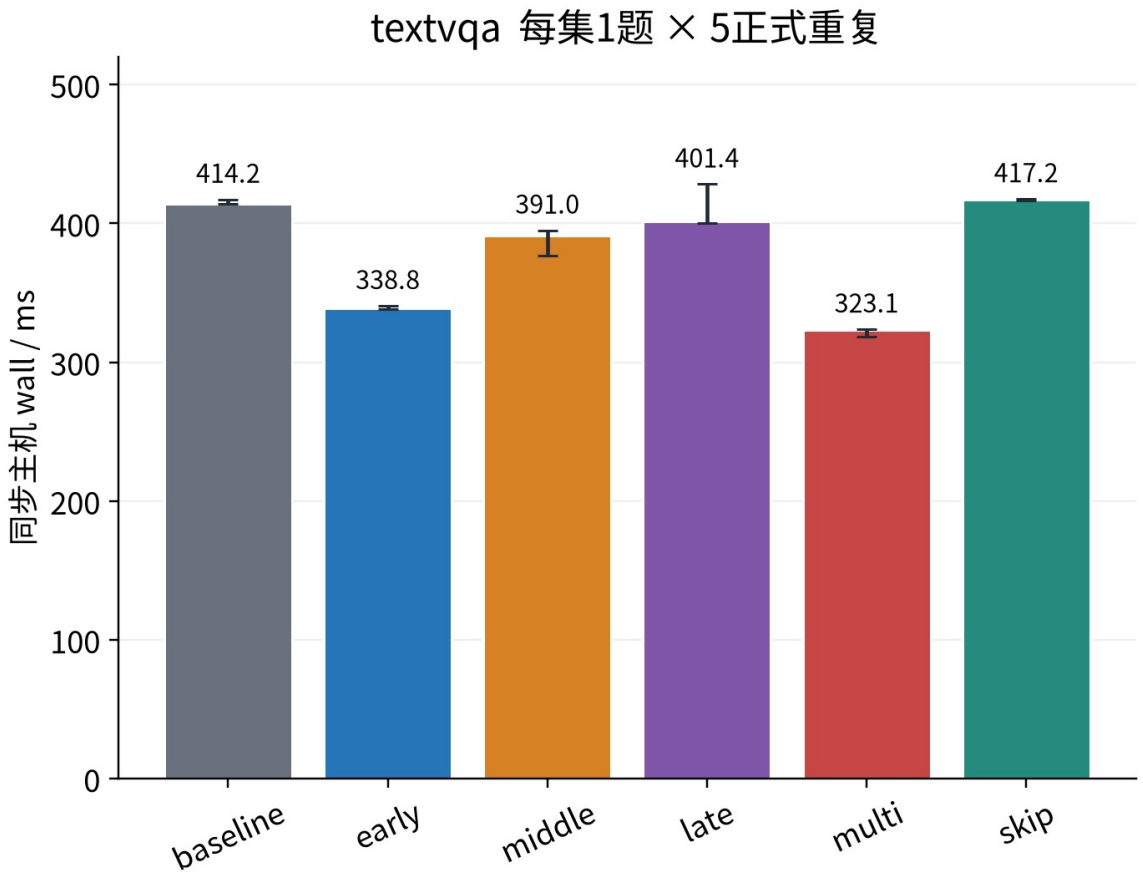


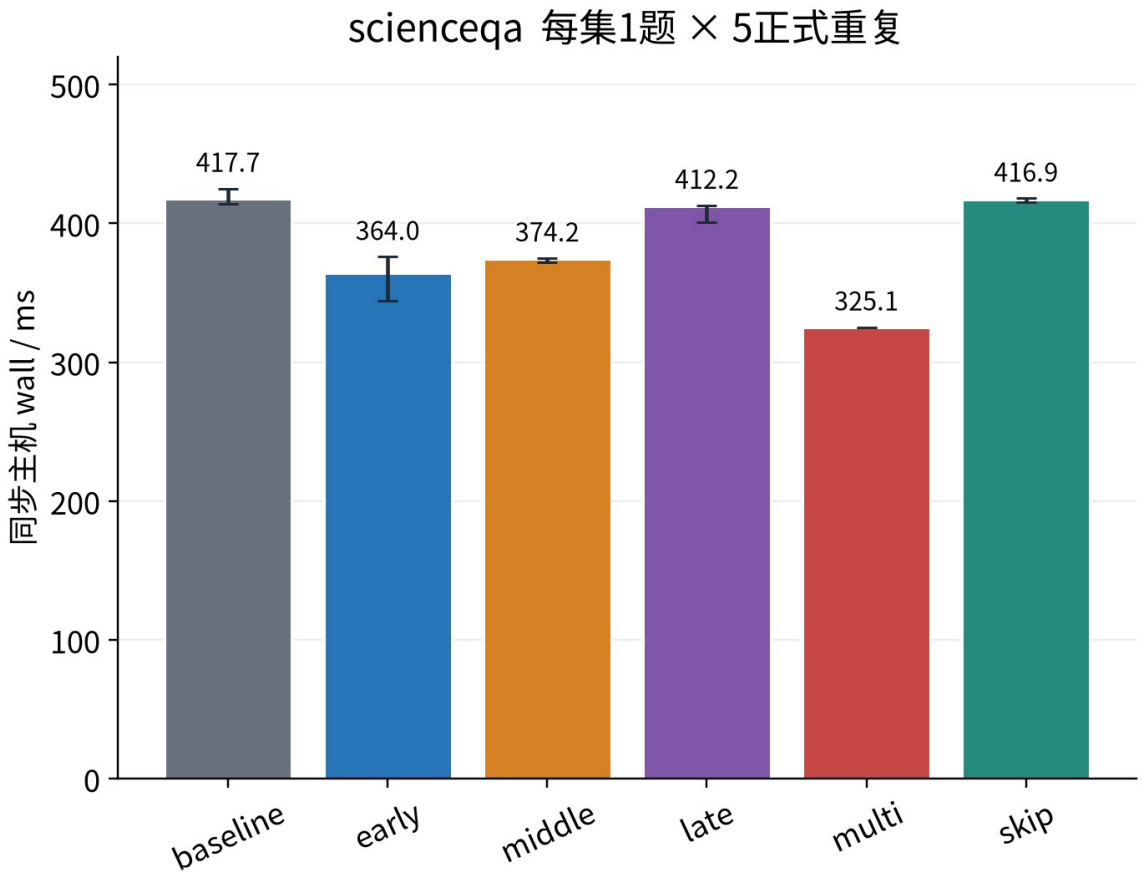


旧主基准 每集 4 题，每题 2 预热 5 正式

wall 为逐题 median 的均值，图内显示实际 G

固定 G 为 16 的速度比较





每集 1 诊断题， 2 预热 5 正式，误差线为 IQR

Skip 旧主基准 0.993× / 1.002×

一致性与真实少算证据

100% 与空 Skip： 比较对象明确，最大误差 0

50% 与 Multi： pre-hook + 矩阵 shape/time

Multi FFN 输入 K 为 512 、 256 、 128

Skip 目标 norm2/MLP 零调用，投影 marker 缺席

证据各自证明实现、数值或执行路径，不能互相替代

真实失败案例与因果边界



baseline

22.

Multi

2.

得分 1 到 0

尚无 Attention 归因实验，不声称已定位被删文字 patch

复现入口与现场操作准备

新入口真实 24 条通过， partial 单独登记

代码、协议、原子记录与证据可离线定位

三项练习：改保留率、改 Skip 、查成本

AI 完成准备；个人独立操作与交流尚未进行